

بِسْمِ اللَّهِ الرَّحْمَنِ الرَّحِيمِ



دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

گروه مهندسی هوش مصنوعی

پایان نامه کارشناسی

رشته مهندسی کامپیوتر گرایش هوش مصنوعی

عنوان پایان نامه

طراحی و توسعه یک سیستم هوش مصنوعی انعطاف پذیر برای تحلیل بازارهای مالی:

از رویکردهای پایه تا ادغامی و چندوجهی

استاد راهنما:

دکتر حمید رضا برادران کاشانی

پژوهشگر:

سید حسین حسینی دولت آبادی

شهریور ۱۴۰۵



دانشگاه اصفهان

دانشکده مهندسی کامپیوتر

گروه مهندسی هوش مصنوعی

پروژه کارشناسی رشته‌ی مهندسی کامپیوتر گرایش هوش مصنوعی آقای سید حسین حسینی دولت آبادی

تحت عنوان

طراحی و توسعه یک سیستم هوش مصنوعی انعطاف پذیر برای تحلیل بازارهای مالی:
از رویکردهای پایه تا ادغامی و چندوجهی

در تاریخ ۱۴۰۵ / ۰۶ / توسط هیأت داوران زیر بررسی و با نمره به تصویب نهایی رسید.

۱- استاد راهنمای پروژه:

دکتر حمید رضا برادران کاشانی

امضا

۲- استاد داور:

دکتر

امضا

امضای مدیر گروه

تشکر و قدردانی

در پایان این مسیر، بر خود لازم می‌دانم از تمامی استادان و افرادی که با راهنمایی، حمایت و انتقال تجربیات خود در شکل‌گیری و پیشبرد این پژوهش نقش داشته‌اند، صمیمانه قدردانی کنم.

در وهله نخست، از جناب آقای دکتر حمیدرضا برادران کاشانی، استاد راهنمای محترم این پروژه، بابت راهنمایی‌های علمی، حمایت و اعتمادی که در طول انجام این پژوهش نسبت به اینجانب داشتند، صمیمانه سپاسگزارم. همراهی ایشان زمینه لازم را برای پیشبرد منظم پروژه و تکمیل این پایان‌نامه فراهم کرد.

همچنین از جناب آقای دکتر محمدرضا شعرفاف که در انجام و نگارش مطالعه مروری این پروژه نقش مؤثری داشتند و با راهنمایی‌های علمی خود به شکل‌گیری بهتر مسیر پژوهش کمک کردند، صمیمانه تشکر می‌کنم. همکاری علمی با ایشان در تدوین مقاله حاصل از مطالعه مروری، بخش مهمی از مسیر اولیه این پژوهش بود.

از آقای مهندس سید عرفان نوربخش، دانشجوی دکتری دانشگاه تگزاس در سن‌آنتونیو، نیز به‌طور ویژه سپاسگزارم. آشنایی و فرصت انجام دوره کارآموزی تحت راهنمایی ایشان، تأثیر قابل توجهی در جهت‌گیری پژوهشی این پروژه داشت. گفتگوها، راهنمایی‌ها و همکاری‌های علمی صورت‌گرفته در این دوره، نقش مهمی در شکل‌گیری و توسعه ایده مربوط به مسئله اتصال قید به مقدار و رسیدن به صورت‌بندی نهایی مسئله پژوهش داشت. همچنین همکاری ایشان در مقاله مروری این پروژه برای من بسیار ارزشمند بود و این همکاری بر روی این پایان‌نامه هنوز ادامه دارد.

از جناب آقای دکتر احمدرضا نقش‌نیلچی نیز صمیمانه قدردانی می‌کنم. معرفی تجربیات و پژوهش‌های انجام‌شده در حوزه مالی و پیشنهاد مطالعه پایان‌نامه کارشناسی ارشد آقای مهندس پژمان مظاهری، به من کمک کرد تا در مراحل اولیه پروژه شناخت دقیق‌تری از مسائل پژوهشی حوزه هوش مصنوعی مالی پیدا کنم و مسیر ذهنی روشن‌تری برای ادامه پژوهش شکل دهم.

همچنین از جناب آقای دکتر حسین کارشناس که با راهنمایی‌های اولیه ایشان توانستم مسیر شروع را به‌درستی انتخاب و پیش ببرم.

در نهایت، از تمامی استادان، دوستان و افرادی که به هر شکل در طول این مسیر با پیشنهادها، نقدها و حمایت‌های خود در انجام این پروژه همراه من بودند، صمیمانه سپاسگزارم.

تقدیم به

به پدر و مادرم؛

آنان که بی‌هیاهو،

تمام راه را با عشق، صبوری و امید هموار کردند،

مهرشان پناه روزهای سخت،

دعایشان روشنای مسیر

و حضورشان آرامش همیشگی من بوده

و هر آنچه امروز هستم،

ریشه در محبت و فداکاری بی‌دریغشان دارد.

و به خانواده عزیزم؛

که حضورشان آرامش راه،

دلگرمی روزهای دشوار

و روشنایی مسیرم بوده است.

این اندک دستاورد را

با تمام عشق و سپاس،

به شما تقدیم می‌کنم.

چکیده:

هوش مصنوعی و به‌ویژه مدل‌های زبانی بزرگ در سال‌های اخیر نقش مهمی در پردازش و تحلیل اطلاعات مالی یافته‌اند. یکی از چالش‌های مهم در این حوزه، توانایی این مدل‌ها در انتخاب صحیح میان چند مقدار عددی معتبر و هم‌زمان است که هر یک به قید یا زمینه‌ای متفاوت، مانند سال، مبنای گزارش‌دهی، مبنای ارزی یا دامنه سازمانی وابسته‌اند. در چنین شرایطی، مدل ممکن است مقداری واقعی و موجود در منبع را انتخاب کند، اما آن مقدار متعلق به قید نادرستی باشد. این نوع خطا در این پژوهش با عنوان مقدار منبع با قید نادرست تعریف شده و از خطاهایی مانند توهم محتوایی متمایز در نظر گرفته می‌شود.

هدف اصلی این پایان‌نامه، بررسی نظام‌مند این نوع خطا در وظیفه پرسش‌وپاسخ مالی است. برای این منظور، مفهوم اتصال قید به مقدار به‌عنوان چارچوب تحلیلی مسئله در نظر گرفته شد و مجموعه ارزیابی فین‌اسکوپ طراحی و توسعه یافت. نسخه نهایی این مجموعه شامل ۸۵۶ پیکربندی و ۱۰۷۱۲ پرسش است که در قالب پرسش‌های دوقلوی متقابل، چهار خانواده قیدی اصلی شامل مبنای ارائه، مبنای ارزی، موقعیت راهنمایی و دامنه گزارش‌دهی را در سه نسخه مصنوعی و یک بخش مبتنی بر داده‌های واقعی پوشش می‌دهد. همچنین سازوکار مستقلی برای نرمال‌سازی و امتیازدهی پاسخ‌ها طراحی شد که خروجی مدل را به چهار دسته پاسخ صحیح، مقدار منبع با قید نادرست، سایر پاسخ‌های نادرست و پاسخ نامعتبر تفکیک می‌کند.

ارزیابی تجربی سه مدل گما-۲-۲ بی-آی تی، جی‌پی تی-اواس اس-۱۲۰ بی و جی‌پی تی-۵۶ سول نشان داد که با وجود اختلاف قابل توجه در دقت کلی مدل‌ها، خطای انتخاب مقدار از قید نادرست در هر سه مدل مشاهده می‌شود. در تجمیع توصیفی داده‌های مصنوعی، دقت این سه مدل به ترتیب ۷۸٫۳۳، ۹۵٫۱۴ و ۹۸٫۶۱ درصد بود، در حالی که به ترتیب ۱۴۳، ۴۵ و ۲۰ مورد از این نوع خطا ثبت شد. در اجرای تجربی حاضر، این خطا در مدل‌های دقیق‌تر نیز باقی ماند و در برخی موارد سهم قابل توجهی از خطاهای باقی‌مانده را تشکیل داد. تحلیل دقت زوجی نیز نشان داد که برخی مدل‌ها ممکن است یک جهت از اتصال قید به مقدار را صحیح پاسخ دهند، اما در جهت متقابل همان پیکربندی موفق نباشند.

یافته‌های این پژوهش نشان می‌دهد که دقت کلی به‌تنهایی برای سنجش قابلیت اعتماد مدل‌های زبانی در پرسش‌وپاسخ مالی کافی نیست و بررسی رابطه میان قید درخواست‌شده و مقدار انتخاب‌شده می‌تواند اطلاعات تشخیصی دقیق‌تری درباره رفتار مدل فراهم کند. فین‌اسکوپ می‌تواند به‌عنوان یک محیط کنترل‌شده برای ارزیابی این نوع خطا و مطالعه روش‌های کاهش آن در سامانه‌های هوش مصنوعی مالی مورد استفاده قرار گیرد.

واژگان کلیدی: هوش مصنوعی مالی، پرسش‌وپاسخ مالی، مدل‌های زبانی بزرگ، اتصال قید به مقدار، مقدار منبع با قید نادرست، فین‌اسکوپ.

فهرست مطالب

عنوان	صفحه
فصل اول مقدمه	۸
۱-۱- هدف پروژه	۱۰
۲-۱- کاربردهای پروژه	۱۲
۳-۱- ساختار پایان نامه	۱۳
فصل دوم مفاهیم	۱۴
۱-۲- مقدمه	۱۴
۲-۲- چشم انداز کلی هوش مصنوعی در حوزه مالی	۱۶
۱-۲-۲- رویکردهای مبتنی بر داده های عددی	۱۶
۲-۲-۲- رویکردهای مبتنی بر داده های متنی	۱۷
۳-۲-۲- رویکردهای مبتنی بر داده های تصویری	۱۸
۴-۲-۲- رویکردهای چندوجهی و ادغام داده ها	۱۹
۳-۲-۲- درک و استدلال در داده های مالی	۱۹
۱-۳-۲- تفاوت پیش بینی با درک و استدلال مالی	۲۰
۲-۳-۲- نقش مدل های زبانی بزرگ در تحلیل و استدلال مالی	۲۰
۴-۲- پرسش و پاسخ مالی و بنچمارک های مرتبط	۲۱
۱-۴-۲- بنچمارک FinQA	۲۱
۲-۴-۲- بنچمارک TAT-QA	۲۱
۳-۴-۲- بنچمارک FinanceBench	۲۲
۵-۲- مفاهیم و انواع خطاهای مرتبط	۲۲
۱-۵-۲- توهم	۲۲
۲-۵-۲- خطای بازیابی و انتخاب شواهد	۲۲
۳-۵-۲- خطای استدلال عددی	۲۳
۴-۵-۲- اتصال ویژگی به مقدار	۲۳
۶-۲- شکاف پژوهشی	۲۳
۷-۲- جمع بندی	۲۴
فصل سوم شرح پروژه	۲۵

فهرست مطالب

صفحه	عنوان
۲۵	۱-۳- مقدمه
۲۶	۲-۳- صورت‌بندی مسئله و تعاریف
۲۶	۱-۲-۳- انتخاب مقدار حساس به قید
۲۶	۲-۲-۳- اتصال قید به مقدار
۲۶	۳-۲-۳- تعریف خطای WQSV
۲۷	۴-۲-۳- انواع خروجی در فین‌اسکوپ
۲۷	۳-۳- استخراج و سازمان‌دهی خانواده‌های قیدی
۲۸	۱-۳-۳- مبنای ارائه
۲۸	۲-۳-۳- مبنای ارزی
۲۸	۳-۳-۳- موقعیت راهنمایی یا عملکرد
۲۸	۴-۳-۳- دامنه گزارش‌دهی
۲۹	۴-۳- طراحی و ساخت فین‌اسکوپ
۲۹	۱-۴-۳- ساختار کلی یک پیکربندی
۲۹	۲-۴-۳- نسخه مصنوعی ورژن V1
۳۰	۳-۴-۳- نسخه مصنوعی ورژن V2
۳۰	۴-۴-۳- نسخه مصنوعی ورژن V3
۳۰	۵-۴-۳- بخش مبتنی بر نمونه‌های واقعی
۳۱	۶-۴-۳- اندازه و ترکیب مجموعه داده
۳۱	۵-۳- اعتبارسنجی و کنترل کیفیت
۳۱	۱-۵-۳- اعتبارسنجی خودکار
۳۲	۲-۵-۳- اعتبارسنجی انسانی
۳۲	۳-۵-۳- کنترل میان‌برها و نشت اطلاعات
۳۳	۴-۵-۳- تثبیت نسخه نهایی
۳۳	۶-۳- زیرساخت ارزیابی
۳۳	۱-۶-۳- نرمال‌سازی پاسخ‌ها
۳۴	۲-۶-۳- سازوکار امتیازدهی

فهرست مطالب

صفحه	عنوان
۳۴	۳-۶-۳-اطلاعات تشخیصی خروجی
۳۵	۳-۶-۴- پروتکل اجرای ارزیابی و بازتولیدپذیری
۳۶	۳-۷- مشخصات نسخه نهایی فین اسکوپ
۳۷	۳-۸- جمع بندی
۳۸	فصل چهارم نتایج و ارزیابی
۳۸	۴-۱- مقدمه
۳۹	۴-۲- تنظیمات آزمایش
۳۹	۴-۲-۱- مدل های مورد ارزیابی
۴۰	۴-۲-۲- تنظیمات تولید پاسخ
۴۱	۴-۲-۳- سیاست دستور ورودی
۴۱	۴-۳- معیارهای ارزیابی
۴۱	۴-۳-۱- دقت
۴۱	۴-۳-۲- نرخ خطای انتخاب مقدار از قید نادرست
۴۲	۴-۳-۳- دقت زوجی
۴۳	۴-۴- نتایج کلی مدل ها
۴۴	۴-۵- تحلیل عملکرد در نسخه های مصنوعی
۴۵	۴-۶- تحلیل پرسش های دوقلو و خطای WQSV
۴۵	۴-۶-۱- تحلیل در سطح پیکربندی
۴۶	۴-۶-۲- سهم WQSV از خطاهای مدل
۴۶	۴-۷- مقایسه داده های مصنوعی و داده های واقعی
۴۸	۴-۸- تحلیل آماری و خطاها
۴۸	۴-۸-۱- مقایسه زوجی مدل ها
۴۹	۴-۸-۲- تحلیل خطاهای مشترک
۴۹	۴-۸-۳- محدودیت های نتایج تجربی
۵۰	۴-۹- جمع بندی
۵۲	فصل پنجم نتیجه گیری و پیشنهادات

فهرست مطالب

صفحه	عنوان
۵۲.....	۵-۱- مقدمه
۵۳.....	۵-۲- جمع‌بندی پژوهش.....
۵۴.....	۵-۳- یافته‌های اصلی پژوهش.....
۵۵.....	۵-۴- محدودیت‌های پژوهش.....
۵۶.....	۵-۵- پیشنهادها برای کارهای آینده
۵۷.....	۵-۶- جمع‌بندی
۵۸.....	منابع:.....

فهرست شکل‌ها

صفحه

عنوان

شکل ۱-۲: فرایند شناسایی، غربالگری و انتخاب مطالعات در مرور نظام‌مند بر اساس چارچوب	
PRISMA 2020.....	۱۶

فهرست جدول‌ها

عنوان	صفحه
جدول ۱-۳: تعداد پیکربندی‌ها و پرسش‌ها در بخش‌های مختلف فین‌اسکوپ	۳۱
جدول ۲-۳: مشخصات نسخه نهایی و اجزای ارزیابی فین‌اسکوپ	۳۶
جدول ۱-۴: مدل‌های منتخب مورد استفاده در ارزیابی تجربی	۳۹
جدول ۲-۴: تنظیمات اصلی تولید پاسخ در آزمایش‌ها	۴۰
جدول ۳-۴: معیارهای اصلی مورد استفاده در ارزیابی	۴۲
جدول ۴-۴: دقت و تعداد خطاهای WQSV سه مدل منتخب در بخش‌های مختلف فین‌اسکوپ	۴۳
جدول ۵-۴: تجمیع توصیفی نتایج سه بخش مصنوعی	۴۴
جدول ۶-۴: دقت زوجی سه مدل در بخش‌های مختلف	۴۵
جدول ۷-۴: سهم WQSV از خطاهای مدل‌ها در سه بخش مصنوعی	۴۶
جدول ۸-۴: مقایسه توصیفی دقت مدل‌ها در داده‌های مصنوعی و واقعی	۴۷
جدول ۹-۴: مقایسه توصیفی نرخ WQSV در داده‌های مصنوعی و واقعی	۴۷
جدول ۱۰-۴: نتایج آزمون مک‌نمار با اصلاح هولم در V1	۴۸
جدول ۱۱-۴: نتایج آزمون مک‌نمار با اصلاح هولم در V2	۴۸
جدول ۱۲-۴: نتایج آزمون مک‌نمار با اصلاح هولم در V3	۴۹

مخفف‌ها:

MDSE	Model-Driven Software Engineering
LLM	Large Language Model
SLR	Systematic Literature Review
API	Application Programming Interface
LSTM	Long Short-Term Memory
GRU	Gated Recurrent Unit
QVB	Qualifier-to-Value Binding
WQSV	Wrong Qualifier Source Value
RAG	Retrieval-Augmented Generation
GPT	Generative Pre-trained Transformer
FX	Foreign Exchange
PRISMA	Preferred Reporting Items for Systematic Reviews and Meta-Analyses

فصل اول

مقدمه

هوش مصنوعی در سال‌های اخیر به یکی از ابزارهای مهم برای پردازش، تحلیل و تفسیر اطلاعات مالی تبدیل شده است. کاربرد این فناوری تنها به پیش‌بینی قیمت یا جهت حرکت بازار محدود نیست و حوزه‌هایی مانند تحلیل گزارش‌های مالی، استخراج اطلاعات، پرسش‌وپاسخ مالی، استدلال عددی و تفسیر اطلاعات متنی و جدولی را نیز دربرمی‌گیرد. با توسعه مدل‌های زبانی بزرگ^۱، دامنه کاربرد هوش مصنوعی در حوزه مالی از پردازش صرف داده‌های عددی فراتر رفته و تحلیل زبان، استدلال و استفاده از اطلاعات ساخت‌یافته و غیرساخت‌یافته نیز به بخش مهمی از پژوهش‌های این حوزه تبدیل شده است [۱].

در مرحله ابتدایی این پروژه، مسئله در چارچوب گسترده‌تری از هوش مصنوعی برای تحلیل بازارهای مالی تعریف شده بود. طرح اولیه پروژه، بررسی رویکردهای مختلف از مدل‌های پایه تا روش‌های ادغامی و چندوجهی^۲ را شامل می‌شد و داده‌های عددی، متنی و تصویری را به‌عنوان مسیرهای احتمالی توسعه در نظر می‌گرفت. موضوع مصوب اولیه پروژه نیز «طراحی و توسعه یک سیستم هوش مصنوعی انعطاف‌پذیر برای تحلیل بازارهای مالی: از رویکردهای پایه تا ادغامی و چندوجهی» بوده است.

به‌منظور انتخاب یک مسئله مشخص و قابل‌مطالعه، در نخستین مرحله پروژه یک بررسی نظام‌مند از پژوهش‌های مرتبط با هوش مصنوعی در حوزه مالی انجام شد. این مطالعه، پژوهش‌های سال‌های ۲۰۲۱ تا ۲۰۲۵ را در مسیرهای مختلف داده‌های عددی، متنی، تصویری و چندوجهی مورد بررسی قرار داد. نتایج این بررسی، علاوه بر ترسیم فضای کلی پژوهش، موضوعاتی مانند درک معنایی، اعتبارسنجی در داده‌های واقعی، بازتولیدپذیری و نیاز به ارزیابی نظام‌مندتر سامانه‌های هوش مصنوعی مالی را به‌عنوان موضوعات قابل‌توجه در ادامه پژوهش مشخص کرد. جزئیات روش انجام این مرور نظام‌مند و نتایج حاصل از آن در فصل دوم ارائه خواهد شد.

^۱ Large Language Models (LLM)

^۲ MultiModal

این مطالعه مروری به‌طور مستقیم برای شناسایی مسئله نهایی این پایان‌نامه طراحی نشده بود؛ بلکه نقش آن، شناخت فضای پژوهش و محدود کردن تدریجی دامنه پروژه بود. در ادامه، تمرکز پروژه به سمت مسائل مرتبط با درک و استدلال در داده‌های مالی و به‌ویژه حوزه پرسش‌وپاسخ مالی^۱ هدایت شد.

در این حوزه، مجموعه‌داده FinQA برای ارزیابی استدلال عددی بر روی گزارش‌های مالی طراحی شده و شامل پرسش‌هایی است که پاسخ به آن‌ها به ترکیب اطلاعات موجود در متن و جدول و انجام زنجیره‌هایی از استدلال نیاز دارد [۲]. به‌طور مشابه، در مجموعه‌داده TAT-QA مسئله پرسش‌وپاسخ بر روی محتوای ترکیبی متن و جدول را بررسی می‌کند و بر استخراج اطلاعات مرتبط و انجام استدلال بر روی داده‌های مالی متمرکز است [۳]. همچنین FinanceBench ارزیابی مدل‌های زبانی بزرگ را در پرسش‌وپاسخ مالی مبتنی بر اسناد واقعی شرکت‌های عمومی دنبال می‌کند و برای پرسش‌ها، پاسخ و شواهد مرتبط را نیز در نظر می‌گیرد [۴].

بررسی دقیق‌تر چنین مسائل و نمونه‌هایی، توجه این پروژه را به یک حالت مشخص از خطای انتخاب مقدار جلب کرد. در گزارش‌ها و اسناد مالی معمولاً چند مقدار عددی معتبر به‌صورت هم‌زمان وجود دارند که هر یک به شرایط و قیود متفاوتی وابسته‌اند. برای مثال، یک شاخص مالی ممکن است برای سال‌های مختلف، مبنای گزارش‌دهی متفاوت، مبنای ارزی مختلف، دامنه‌های سازمانی متفاوت یا موقعیت‌هایی نظیر مقدار پیش‌بینی‌شده و مقدار تحقق‌یافته ارائه شده باشد.

در چنین شرایطی، پاسخ صحیح تنها از طریق یافتن یک عدد موجود در متن تعیین نمی‌شود؛ بلکه سامانه باید قید معنایی مطرح‌شده در پرسش را به مقدار متناظر با آن متصل کند.

برای نمونه، فرض شود یک گزارش مالی به‌طور هم‌زمان شامل «درآمد گزارش‌شده سال ۲۰۲۴»، «درآمد تعدیل‌شده سال ۲۰۲۴»، «درآمد تعدیل‌شده سال ۲۰۲۴ بر مبنای نرخ ارز ثابت» و «درآمد تعدیل‌شده سال ۲۰۲۳» باشد. اگر پرسش، درآمد تعدیل‌شده سال ۲۰۲۴ بر مبنای نرخ ارز ثابت را درخواست کند، تنها یکی از این مقادیر پاسخ صحیح خواهد بود. اگر مدل به‌جای آن، درآمد تعدیل‌شده سال ۲۰۲۴ بر مبنای گزارش‌شده را انتخاب کند، مقدار تولیدشده می‌تواند کاملاً واقعی و موجود در همان منبع باشد؛ با این حال، از نظر معنایی پاسخ صحیح پرسش نیست.

این حالت با شکل متداول توهم محتوایی^۲ متفاوت است [۵]؛ زیرا مقدار انتخاب‌شده در منبع وجود دارد، اما به قید مورد درخواست پرسش تعلق ندارد. بنابراین، مسئله در اینجا نه تولید یک مقدار فاقد پشتوانه در منبع، بلکه انتخاب یک مقدار معتبر با ارتباط معنایی نادرست نسبت به قید پرسش است.

^۱ Financial Question Answering

^۲ Hallucination

در این پایان‌نامه، این مسئله با عبارت **انتخاب مقدار حساس به قید**^۱ توصیف می‌شود. برای صورت‌بندی عملیاتی آن نیز از مفهوم **اتصال قید به مقدار**^۲ استفاده شده است. منظور از این مفهوم، توانایی مدل در برقراری ارتباط صحیح میان قید یا مجموعه قیود موجود در پرسش و مقدار متناظر با آن‌ها در داده مالی است.

در چارچوب این پژوهش، حالتی که مدل یک مقدار موجود در منبع را انتخاب کند، اما این مقدار متعلق به یک قید رقیب و نه قید درخواست‌شده در پرسش باشد، با عنوان **مقدار منبع با قید نادرست**^۳ تعریف می‌شود.

بر اساس این مسئله، بنچمارک فین‌اسکوپ^۴ طراحی و توسعه داده شده است. هدف از این طراحی صرفاً تعیین درست یا نادرست بودن پاسخ نهایی مدل نیست، بلکه فراهم کردن یک محیط کنترل‌شده برای بررسی این موضوع است که آیا مدل می‌تواند در حضور چند مقدار معتبر، مقدار متناظر با قید مورد درخواست را به درستی انتخاب کند و در صورت تولید پاسخ نادرست، آیا پاسخ انتخاب‌شده با یکی از مقادیر معتبر متعلق به قیود رقیب مطابقت دارد یا خیر.

به این ترتیب، تمرکز اصلی این پروژه بر مطالعه و ارزیابی یک نوع مشخص از خطای انتخاب مقدار در سامانه‌های هوش مصنوعی مالی قرار دارد؛ خطایی که در آن پاسخ مدل ممکن است از نظر عددی معتبر و موجود در منبع باشد، اما به دلیل اتصال نادرست میان قید و مقدار، از نظر معنایی پاسخ صحیح پرسش محسوب نشود.

۱-۱- هدف پروژه

هدف اصلی این پروژه، طراحی و توسعه یک چارچوب کنترل‌شده برای بررسی و ارزیابی توانایی مدل‌های هوش مصنوعی در انتخاب مقدار صحیح بر اساس قیود معنایی موجود در پرسش‌های مالی است. تمرکز پروژه بر شرایطی است که چند مقدار معتبر به‌طور هم‌زمان در متن یا جدول وجود دارند، اما تنها یکی از آن‌ها با قید یا مجموعه قیود مطرح‌شده در پرسش مطابقت دارد.

برای مطالعه این مسئله، محیط ارزیابی به‌گونه‌ای طراحی شده است که مقدار هدف، قید هدف و مقادیر رقیب به‌صورت صریح مشخص باشند و بتوان خطاهای مرتبط با اتصال نادرست قید به مقدار را به‌صورت کنترل‌شده بررسی کرد.

^۱ Qualifier-Sensitive Value Selection

^۲ Qualifier-to-Value Binding (QVB)

^۳ Wrong Qualifier Source Value (WQSV)

^۴ FinScope

در بسیاری از مجموعه داده‌های پرسش و پاسخ مالی، قابلیت‌هایی مانند استخراج شواهد، استفاده از اطلاعات متنی و جدولی و استدلال عددی به صورت هم‌زمان مورد ارزیابی قرار می‌گیرند [۲]–[۴]. از این رو، یک پاسخ نادرست لزوماً نشان نمی‌دهد که خطا دقیقاً در کدام مرحله رخ داده است. هدف بنچمارک و چارچوب ارزیابی توسعه یافته، ایجاد یک محیط ارزیابی کنترل شده‌تر است که در آن مقدار هدف، قید هدف و مقادیر رقیب به صورت صریح مشخص باشند و بتوان نوع خاصی از خطای انتخاب مقدار را جداگانه مطالعه کرد.

برای دستیابی به این هدف، در این پروژه مجموعه داده‌ای در سه نسخه مصنوعی و یک بخش مبتنی بر نمونه‌های واقعی طراحی شده است. نسخه‌های مصنوعی امکان کنترل دقیق ساختار نمونه‌ها، مقادیر رقیب و قیود معنایی را فراهم می‌کنند، در حالی که بخش واقعی برای بررسی وجود طبیعی این نوع ابهام در داده‌های مالی مورد استفاده قرار می‌گیرد. هدف بخش واقعی، برآورد شیوع این پدیده در کل حوزه مالی نیست، بلکه نشان دادن این موضوع است که مسئله مورد مطالعه صرفاً محصول طراحی مصنوعی مجموعه داده نیست. در ساختار فعلی فین‌اسکوپ چهار خانواده اصلی از قیود مالی مورد بررسی قرار گرفته‌اند: **مبنای ارائه^۱**، **مبنای ارزی^۲**، **موقعیت راهنمایی یا عملکرد^۳** و **دامنه گزارش‌دهی^۴**. نحوه استخراج، تعریف و اعتبارسنجی این خانواده‌ها در فصل سوم تشریح خواهد شد.

از دیگر اهداف پروژه، طراحی یک فرایند ارزیابی بازتولیدپذیر برای خروجی مدل‌ها است. به همین منظور، سازوکار امتیازدهی فین‌اسکوپ به گونه‌ای طراحی شده است که پاسخ‌های مدل را تنها به دو گروه درست و نادرست تقسیم نکند، بلکه آن‌ها را در دسته‌های صحیح^۵، مقدار منبع با قید نادرست^۶، سایر موارد نادرست^۷ و نامعتبر^۸ قرار دهد. به طور کلی، اهداف اصلی این پروژه را می‌توان در موارد زیر خلاصه کرد:

۱. صورت‌بندی مسئله انتخاب مقدار حساس به قید در داده‌های مالی؛
۲. استخراج و سازمان‌دهی خانواده‌های اصلی قیود مورد استفاده در فین‌اسکوپ؛
۳. طراحی مجموعه داده‌های مصنوعی کنترل شده برای مطالعه این نوع خطا؛
۴. ایجاد و اعتبارسنجی یک بخش مبتنی بر نمونه‌های واقعی مالی؛
۵. توسعه یک سازوکار امتیازدهی تشخیصی برای تفکیک انواع پاسخ‌های نادرست؛
۶. ارزیابی تجربی رفتار مدل‌های مختلف هوش مصنوعی بر روی فین‌اسکوپ؛

¹ Presentation Basis

² FX Basis

³ Guidance Position

⁴ Reporting Scope

⁵ CORRECT

⁶ WQSV

⁷ OTHER WRONG

⁸ INVALID

این اهداف باعث می‌شوند تمرکز پروژه از صرف اندازه‌گیری دقت کلی مدل‌ها فراتر رفته و به تحلیل دقیق‌تر علت و نوع خطا در انتخاب مقادیر مالی معطوف شود.

۲-۱- کاربردهای پروژه

کاربرد اصلی فین‌اسکوپ، ارزیابی و تحلیل خطا در سامانه‌های هوش مصنوعی مالی است. این پروژه برخلاف سامانه‌هایی که برای پیش‌بینی قیمت، تولید سیگنال معاملاتی یا ارائه توصیه سرمایه‌گذاری طراحی می‌شوند، مستقیماً برای تصمیم‌گیری مالی به کار نمی‌رود؛ بلکه هدف آن بررسی میزان قابلیت اعتماد مدل‌ها در انتخاب صحیح مقادیر مالی تحت قیود معنایی مختلف است.

یکی از کاربردهای اصلی آن، ارزیابی سامانه‌های پرسش و پاسخ مالی است. در چنین سامانه‌هایی، مدل باید اطلاعات متنی و جدولی را درک کرده و مقدار مناسب را بر اساس سؤال انتخاب کن [۲] [۴]. فین‌اسکوپ این امکان را فراهم می‌کند که علاوه بر سنجش صحت پاسخ نهایی، مشخص شود آیا پاسخ نادرست با یکی از مقادیر معتبر اما متعلق به قید رقیب مطابقت دارد یا خیر.

کاربرد دیگر پروژه، تحلیل تشخیصی خطا و مقایسه مدل‌ها یا نسخه‌های مختلف یک سامانه است. ممکن است دو مدل از نظر دقت کلی عملکرد مشابهی داشته باشند، اما در برخی خانواده‌های قیدی رفتار متفاوتی نشان دهند. تحلیل نتایج در سطح خانواده‌های مختلف می‌تواند چنین تفاوت‌هایی را آشکار کرده و برای آزمون بازگشت^۱ پس از تغییر مدل، دستور ورودی یا سایر اجزای سامانه مورد استفاده قرار گیرد.

همچنین، فین‌اسکوپ می‌تواند برای مطالعه مرحله انتخاب مقدار در سامانه‌های مبتنی بر تولید تقویت‌شده با بازیابی^۲ مورد استفاده قرار گیرد [۶]؛ به‌ویژه در شرایطی که سند یا زمینه مرتبط از قبل در اختیار مدل قرار گرفته است. با این حال، این بنچمارک برای ارزیابی جامع خود فرایند بازیابی طراحی نشده و تمرکز آن بر انتخاب صحیح مقدار از زمینه ارائه‌شده است.

از دیدگاه پژوهشی و مهندسی، ساختار کنترل‌شده داده و سازوکار امتیازدهی پروژه امکان بررسی رفتار مدل‌ها در خانواده‌های مختلف قیدی، تحلیل میانبرهای احتمالی و اجرای ارزیابی‌های بازتولیدپذیر را فراهم می‌کند. بنابراین، فین‌اسکوپ را می‌توان در درجه نخست یک زیرساخت ارزیابی و تشخیص خطا برای سامانه‌های هوش مصنوعی مالی در نظر گرفت.

^۱ Regression Testing

^۲ Retrieval-Augmented Generation (RAG)

۱-۳- ساختار پایان نامه

این پایان نامه در پنج فصل اصلی تنظیم شده است. ساختار فصل‌ها به گونه‌ای طراحی شده که ابتدا زمینه نظری و پژوهشی مسئله معرفی شود، سپس روش طراحی و توسعه فین‌اسکوپ تشریح گردد و در ادامه نتایج تجربی و جمع‌بندی نهایی ارائه شود.

در **فصل اول**، مسئله اصلی پروژه، هدف پژوهش و کاربردهای آن معرفی می‌شوند. در این فصل، ابتدا مسئله انتخاب مقدار حساس به قید در داده‌های مالی تشریح شده و سپس مفهوم اتصال قید به مقدار و خطای مقدار منبع با قید نادرست معرفی می‌شوند. در ادامه، هدف پروژه، کاربردهای فین‌اسکوپ و ساختار کلی پایان نامه بیان می‌شود.

در **فصل دوم**، مفاهیم و پیشینه پژوهشی مورد نیاز برای درک مسئله بررسی می‌شوند. ابتدا تصویری کلی از کاربرد هوش مصنوعی در حوزه مالی ارائه شده و سپس تمرکز به مسائل مرتبط با درک و استدلال در داده‌های مالی و حوزه پرسش و پاسخ مالی معطوف می‌شود. در ادامه، مجموعه داده‌ها و بنچمارک‌های مرتبط با پرسش و پاسخ و استدلال عددی مالی، مرور می‌شوند. همچنین مفاهیم و انواع خطاهای نزدیک به مسئله این پژوهش، مانند توهم، خطای بازیابی^۱، خطای انتخاب شواهد و خطای انتخاب مقدار بررسی شده و در پایان، شکاف پژوهشی مورد هدف این پایان نامه مشخص می‌شود.

در **فصل سوم**، طراحی و توسعه بنچمارک فین‌اسکوپ تشریح می‌شود. در ابتدا، مسئله انتخاب مقدار حساس به قید و تعریف عملیاتی ارائه شده و نحوه استخراج و سازمان‌دهی خانواده‌های مختلف قیود مالی توضیح داده می‌شود. سپس فرایند ساخت داده‌های مصنوعی در سه نسخه و همچنین نحوه ایجاد بخش مبتنی بر نمونه‌های واقعی بیان می‌شود. در ادامه، مراحل اعتبارسنجی خودکار و انسانی، داوری نهایی نمونه‌ها، کنترل میان‌برها و نشت اطلاعات و فرایند تثبیت نسخه نهایی بنچمارک تشریح می‌شوند. در بخش پایانی این فصل نیز اجزای زیرساخت ارزیابی، شامل نرمال‌سازی پاسخ‌ها، سازوکار امتیازدهی، پروتکل ارزیابی و زیرساخت نرم‌افزاری اجرای ارزیابی معرفی خواهند شد.

در **فصل چهارم**، مدل‌های مورد ارزیابی، تنظیمات آزمایش و معیارهای ارزیابی معرفی شده و نتایج تجربی از منظر عملکرد کلی، خانواده‌های قیدی، داده‌های مصنوعی و واقعی و انواع خطاها تحلیل می‌شوند.

در **فصل پنجم**، نتایج اصلی پژوهش جمع‌بندی شده و یافته‌های حاصل از طراحی و ارزیابی فین‌اسکوپ در ارتباط با اهداف پروژه تفسیر می‌شوند. همچنین محدودیت‌های پژوهش و مسیرهای پیشنهادی برای ادامه کار، از جمله گسترش خانواده‌های قیود، توسعه بخش واقعی مجموعه داده و بهبود زیرساخت ارزیابی، مطرح خواهند شد.

^۱ Retrieval Failure

فصل دوم

مفاهیم

۲-۱- مقدمه

برای بررسی مسئله انتخاب مقدار حساس به قید و جایگاه بنچمارک فین اسکوپ، لازم است ابتدا زمینه پژوهشی گسترده‌تری که این مسئله در آن قرار می‌گیرد معرفی شود. هوش مصنوعی در حوزه مالی طی سال‌های اخیر از روش‌های مبتنی بر داده‌های عددی و سری‌های زمانی فراتر رفته و به استفاده از منابع متنی، تصویری و ترکیب چند نوع داده گسترش یافته است. این تحول، علاوه بر مسائل سنتی پیش‌بینی، زمینه را برای مطالعه مسائلی مانند تحلیل اسناد مالی، استخراج اطلاعات، پرسش‌وپاسخ، استدلال عددی و درک معنایی فراهم کرده است [۷].

در مرحله نخست این پروژه، به‌منظور شناخت ساختار کلی این حوزه و انتخاب یک مسئله پژوهشی مشخص، یک مطالعه نظام‌مند^۱ [۱۴] بر روی پژوهش‌های مرتبط با هوش مصنوعی در بازارهای مالی انجام شد. این مطالعه با استفاده از یک فرایند غربالگری نظام‌مند و با الهام از دستورالعمل موارد ترجیحی گزارش‌دهی برای مرورهای نظام‌مند و فراتحلیل‌ها^۲ انجام شد و مطالعات منتشرشده در بازه سال‌های ۲۰۲۱ تا ۲۰۲۵ را بررسی کرد. پس از مراحل شناسایی، حذف موارد تکراری، غربالگری و اسنوبالینگ^۳، مجموعه نهایی شامل ۹۷ مطالعه اولیه بود، که در شکل ۱-۲ نشان داده شده است. در این بررسی، پژوهش‌ها از منظر نوع داده، معماری مدل، روش ترکیب داده‌ها، بازار هدف و شیوه ارزیابی تحلیل شدند.

نتایج این مطالعه نشان داد که پژوهش‌های هوش مصنوعی مالی از نظر نوع داده و روش مدل‌سازی طیف گسترده‌ای دارند. بخشی از مطالعات همچنان بر سری‌های زمانی عددی و شاخص‌های مالی متمرکز

^۱ Systematic Literature Review (SLR)


^۲ Preferred Reporting Items for Systematic Reviews and Meta-Analyses (PRISMA)

^۳ Forward and Backward Snowballing

هستند، گروه قابل توجهی از نمایش‌های تصویری مانند نمودارهای شمعی استفاده می‌کنند و تعداد محدودتری از پژوهش‌ها به ترکیب داده‌های تصویری و متنی روی آورده‌اند. در مجموعه ۹۷ مطالعه بررسی شده، ۵۴ مطالعه از داده‌های تصویری، ۲۳ مطالعه از داده‌های صرفاً عددی و ۲۰ مطالعه از ترکیب داده‌های تصویری و متنی (ادغامی و چندوجهی) استفاده کرده‌اند.

با وجود آنکه مطالعه مروری انجام شده در این پروژه عمدتاً بر تحلیل و پیش‌بینی بازارهای مالی تمرکز داشته است، نتایج آن چالش‌هایی فراتر از صرف پیش‌بینی را نیز نشان داد؛ از جمله محدودیت در درک معنایی داده‌ها، نبود ارزیابی کافی در شرایط واقعی، ضعف در بازتولیدپذیری، محدودیت در تفسیرپذیری مدل‌ها و نیاز به شیوه‌های ارزیابی استانداردتر. این مشاهدات در کنار گسترش مدل‌های زبانی بزرگ در حوزه مالی، زمینه لازم را برای حرکت از مسائل صرفاً پیش‌بینی‌محور به سمت مسائل مرتبط با **درک و استدلال مالی** فراهم کردند.

بر این اساس، در این فصل ابتدا تصویری فشرده از رویکردهای اصلی هوش مصنوعی در حوزه مالی ارائه می‌شود. سپس تمرکز به حوزه درک و استدلال مالی و به‌ویژه پرسش‌وپاسخ مالی منتقل خواهد شد. در ادامه، بنچمارک‌های مهم این حوزه و انواع خطاهای نزدیک به مسئله انتخاب مقدار بررسی شده و در نهایت شکاف پژوهشی‌ای که طراحی فین‌اسکوپ بر مبنای آن شکل گرفته است تشریح می‌شود.



شکل ۲-۱: فرایند شناسایی، غربالگری و انتخاب مطالعات در مرور نظام‌مند بر اساس چارچوب PRISMA 2020

۲-۲- چشم‌انداز کلی هوش مصنوعی در حوزه مالی

کاربرد هوش مصنوعی در تحلیل داده‌های مالی را می‌توان از منظر نوع داده مورد استفاده به چند مسیر اصلی تقسیم کرد. در مطالعه نظام‌مند انجام‌شده در این پروژه، پژوهش‌ها بر اساس نحوه استفاده از داده‌های عددی، متنی، تصویری و چندوجهی مورد بررسی قرار گرفتند. این تقسیم‌بندی به معنای مستقل بودن کامل این مسیرها از یکدیگر نیست؛ بسیاری از سامانه‌های جدید از ترکیب دو یا چند نوع داده استفاده می‌کنند. با این حال، این دسته‌بندی تصویری مناسب از تحول روش‌های هوش مصنوعی در حوزه مالی فراهم می‌کند.

۲-۲-۱ رویکردهای مبتنی بر داده‌های عددی

داده‌های عددی و سری‌های زمانی از قدیمی‌ترین و پرکاربردترین منابع در تحلیل بازارهای مالی محسوب می‌شوند. قیمت باز و بسته‌شدن، پیشینه و کمینه قیمت، حجم معاملات و شاخص‌های فنی نمونه‌هایی از داده‌هایی هستند که در بسیاری از روش‌های پیش‌بینی مالی مورد استفاده قرار می‌گیرند. در روش‌های کلاسیک، تحلیل این داده‌ها عمدتاً بر مدل‌های آماری و روش‌های سنتی سری زمانی متکی بود، اما

با توسعه یادگیری عمیق، معماری‌هایی مانند شبکه‌های عصبی بازگشتی، حافظه کوتاه‌مدت بلندمدت^۱، واحد بازگشتی دروازه‌ای^۲ و در سال‌های اخیر مدل‌های مبتنی بر ترنسفورمر^۳ نیز برای پیش‌بینی روند و نوسان بازار مورد استفاده قرار گرفته‌اند [۷] [۹].

مرور اولورونیمبه و ویکتور^۴ نشان می‌دهد که روش‌های یادگیری عمیق در کاربردهای بازار سهام به‌طور گسترده برای پیش‌بینی، معاملات الگوریتمی و ارزیابی راهبردهای معاملاتی به کار گرفته شده‌اند، با این حال مسائلی مانند تفسیرپذیری و عملکرد در افق‌های زمانی بلندتر همچنان از چالش‌های مهم این حوزه هستند [۷]. همچنین هو و همکاران^۵ در بررسی روش‌های پیش‌بینی قیمت سهام و بازار ارز، کاربرد گسترده مدل‌های یادگیری عمیق را گزارش کرده و محدودیت‌هایی مانند کمبود مدل‌های ترکیبی و تفاوت در شیوه‌های ارزیابی را مطرح کرده‌اند [۸].

از سوی دیگر، مرور گه و همکاران^۶ بر پیش‌بینی نوسان مالی نشان می‌دهد که نبود پروتکل‌های ارزیابی یکنواخت و تفاوت میان داده‌ها و تنظیمات آزمایش، مقایسه مستقیم مدل‌ها را دشوار می‌کند [۹]. این مسئله تنها به مدل‌های پیش‌بینی محدود نیست و اهمیت طراحی ارزیابی‌های کنترل‌شده و بازتولیدپذیر را در سایر مسائل هوش مصنوعی مالی نیز نشان می‌دهد.

در مطالعه نظام‌مند انجام‌شده در این پروژه، ۲۳ مورد از ۹۷ پژوهش نهایی از داده‌های صرفاً عددی استفاده کرده‌اند. با این حال، استفاده صرف از داده‌های عددی محدودیت‌هایی دارد؛ بسیاری از عوامل مؤثر بر تصمیم‌گیری مالی، مانند گزارش‌های شرکت، اخبار، توضیحات مدیریتی و سایر اطلاعات زمینه‌ای، ماهیتی متنی دارند و در یک سری زمانی عددی به‌طور مستقیم بازنمایی نمی‌شوند.

۲-۲-۲ رویکردهای مبتنی بر داده‌های متنی

داده‌های متنی یکی دیگر از منابع مهم اطلاعات در حوزه مالی هستند. اخبار اقتصادی، شبکه‌های اجتماعی، گزارش‌های سالانه شرکت‌ها، افشاهای مالی و متن تماس‌های گزارش درآمد می‌توانند اطلاعاتی را دربرگیرند که در داده‌های صرفاً عددی قابل مشاهده نیستند.

پژوهش‌های اولیه در این حوزه عمدتاً بر تحلیل احساسات مالی متمرکز بودند. هدف این مطالعات، استخراج نگرش مثبت، منفی یا خنثی از اخبار و پیام‌های مرتبط با بازار و استفاده از آن‌ها به‌عنوان متغیر کمکی در پیش‌بینی رفتار قیمت بود. مطالعات مروری مختلف نشان داده‌اند که با توسعه معماری‌های مبتنی

^۱ Long Short-Term Memory (LSTM)

^۲ Gated Recurrent Unit (GRU)

^۳ Transformer

^۴ Olorunnimbe and Viktor

^۵ Hu et al.

^۶ Ge et al.

بر توجه و مدل‌های زبانی، تحلیل متن مالی از روش‌های ساده طبقه‌بندی احساسات به سمت مدل‌سازی عمیق‌تر زمینه و معنا حرکت کرده است [۱]، [۱۰].

ظهور مدل‌های زبانی بزرگ موجب گسترش قابل‌توجه دامنه کاربرد داده‌های متنی در امور مالی شده است. این مدل‌ها علاوه بر تحلیل احساسات، در مسائلی مانند خلاصه‌سازی گزارش‌های مالی، استخراج اطلاعات، تولید گزارش، پاسخ‌گویی به پرسش‌های مالی و استدلال بر روی اسناد مورد استفاده قرار گرفته‌اند [۱]. در نتیجه، مسئله «درک» اطلاعات مالی به‌تدریج به موضوعی مستقل از پیش‌بینی بازار تبدیل شده است.

این تحول برای مسئله مورد مطالعه در این پایان‌نامه اهمیت ویژه‌ای دارد. برخلاف پیش‌بینی مبتنی بر سری زمانی، در پرسش‌وپاسخ مالی مدل باید نه‌تنها اعداد را شناسایی کند، بلکه معنای عباراتی را که این اعداد را توصیف می‌کنند نیز درک کند. تفاوت میان عباراتی مانند «گزارش‌شده»، «تعدیل‌شده»، «بر مبنای نرخ ارز ثابت» یا «راهنمایی مدیریتی» می‌تواند تعیین‌کننده انتخاب مقدار صحیح باشد. از این‌رو، پردازش متن مالی زمینه‌ای مستقیم برای مسئله اتصال قید به مقدار فراهم می‌کند.

۲-۳ رویکردهای مبتنی بر داده‌های تصویری

بخش دیگری از پژوهش‌های هوش مصنوعی مالی از بازنمایی‌های تصویری داده‌های بازار استفاده می‌کنند. نمودارهای شمعی، نمودارهای شاخص‌های فنی و تبدیل‌های سری زمانی به تصویر، از جمله ورودی‌هایی هستند که در این رویکردها استفاده می‌شوند.

مرور ویکاکسونو و همکاران^۱ نشان می‌دهد که الگوهای شمعی به‌طور گسترده در سامانه‌های تحلیل و پیش‌بینی بازار مورد استفاده قرار گرفته‌اند، اما عملکرد این روش‌ها به بازار، بازه زمانی و شرایط اقتصادی وابسته است و هنوز یک روش عمومی و بدون خطا برای استفاده از این الگوها وجود ندارد [۱۱].

در مطالعه نظام‌مند انجام‌شده در این پروژه، رویکردهای تصویری بیشترین سهم را در میان مطالعات نهایی داشته‌اند؛ به‌طوری‌که ۵۴ مطالعه از ۹۷ پژوهش بررسی‌شده از داده‌های تصویری استفاده کرده‌اند. در میان ۷۴ مطالعه‌ای که به‌نوعی ورودی تصویری داشتند، نمودارهای شمعی متداول‌ترین نوع ورودی بودند و در ۴۱ مطالعه مورد استفاده قرار گرفته‌اند. پس از آن، نمایش‌های تصویری شاخص‌های فنی و روش‌های تبدیل سری زمانی به تصویر قرار داشتند.

با وجود اهمیت این دسته از پژوهش‌ها در ترسیم فضای کلی هوش مصنوعی مالی، رویکردهای تصویری مستقیماً در مسئله اصلی فین‌اسکوپ نقش ندارند. دلیل ارائه مختصر آن‌ها در این فصل، نشان‌دادن مسیر

^۱ Wicaksono et al.

گسترده‌تری است که پروژه از آن آغاز شده و مشخص کردن جایگاه مسئله نهایی در میان رویکردهای مختلف هوش مصنوعی در بازارهای مالی است.

۲-۲-۴ رویکردهای چندوجهی و ادغام داده‌ها

محدودیت هر یک از منابع داده به‌تنهایی، پژوهشگران را به سمت استفاده هم‌زمان از چند نوع داده هدایت کرده است. در رویکردهای چندوجهی، اطلاعات عددی، متنی و تصویری می‌توانند در مراحل مختلف مدل با یکدیگر ترکیب شوند.

روش‌های ادغام معمولاً به دسته‌هایی مانند ادغام زودهنگام^۱، ادغام دیرهنگام^۲ و روش‌های مبتنی بر توجه یا ادغام ترکیبی تقسیم می‌شوند. مطالعات این حوزه نشان داده‌اند که ترکیب اطلاعات بازار با اخبار، احساسات و نمایش‌های تصویری می‌تواند در برخی وظایف نسبت به استفاده از یک منبع داده منفرد عملکرد بهتری ایجاد کند [۱۲]، [۱۳].

در مطالعه نظام‌مند انجام‌شده در این پروژه، ۲۰ مورد از ۹۷ مطالعه نهایی از ترکیب داده‌های تصویری و متنی استفاده کرده‌اند. در میان این مطالعات، ادغام دیرهنگام با ۹ مطالعه متداول‌ترین روش بوده و پس از آن ادغام زودهنگام در ۵ مطالعه و روش‌های مبتنی بر توجه و ترکیبی هرکدام در ۳ مطالعه مورد استفاده قرار گرفته‌اند.

این نتایج نشان می‌دهند که بخش قابل‌توجهی از ادبیات هم‌چنان بر رویکردهای تک‌وجهی متکی است و استفاده از معماری‌های چندوجهی پیشرفته نسبتاً محدودتر بوده است. با این حال، هدف پروژه حاضر توسعه یک مدل چندوجهی جدید نیست. مطالعه این مسیر در مرحله اولیه پروژه برای شناخت فضای گسترده پژوهش انجام شد، اما با محدود شدن دامنه، تمرکز پایان‌نامه حاضر بر مسئله درک معنایی و انتخاب صحیح مقدار در داده‌های مالی قرار گرفته است.

۲-۳- درک و استدلال در داده‌های مالی

تحلیل داده‌های مالی تنها به پیش‌بینی قیمت یا روند بازار محدود نمی‌شود. در بسیاری از کاربردها، سامانه باید اطلاعات موجود در گزارش‌ها، جداول و متون مالی را درک کرده و میان مفاهیم، مقادیر و شرایط مختلف ارتباط برقرار کند. با گسترش مدل‌های زبانی بزرگ، مسائلی مانند استخراج اطلاعات، پرسش‌وپاسخ مالی، خلاصه‌سازی اسناد و استدلال بر روی داده‌های مالی اهمیت بیشتری پیدا کرده‌اند [۱].

^۱ Early Fusion

^۲ Late Fusion

در چنین مسائلی، صرف شناسایی یک عدد موجود در سند کافی نیست. مدل باید تشخیص دهد که هر مقدار به چه سال، نوع گزارش، مبنای ارزی، دامنه سازمانی یا وضعیت مالی مربوط است. بنابراین، بخش مهمی از عملکرد مدل به توانایی آن در برقراری ارتباط صحیح میان اطلاعات زبانی و مقادیر عددی وابسته است.

۲-۳-۱ تفاوت پیش‌بینی با درک و استدلال مالی

در مسائل پیش‌بینی، هدف معمولاً برآورد یک مقدار یا وضعیت آینده بر اساس داده‌های گذشته است. در مقابل، در مسائل درک و استدلال مالی، پاسخ مورد نظر از اطلاعات موجود در سند یا زمینه ورودی استخراج یا استنتاج می‌شود. در این حالت، مدل باید علاوه بر شناسایی اطلاعات مرتبط، روابط میان آن‌ها را نیز به‌درستی تفسیر کند.

برای مثال، اگر چند مقدار درآمد در یک گزارش وجود داشته باشد، مدل باید تشخیص دهد کدام مقدار با سال، مبنای گزارش‌دهی و سایر شرایط مطرح‌شده در پرسش مطابقت دارد. در نتیجه، خطای مدل ممکن است حتی در شرایطی رخ دهد که مقدار انتخاب‌شده واقعاً در سند وجود داشته باشد، اما به مفهوم یا قید مورد درخواست مربوط نباشد. این ویژگی، مسائل درک مالی را از وظایف صرفاً پیش‌بینی‌محور متمایز می‌کند.

۲-۳-۲ نقش مدل‌های زبانی بزرگ در تحلیل و استدلال مالی

مدل‌های زبانی بزرگ امکان پردازش و تحلیل حجم زیادی از اطلاعات متنی و ساخت‌یافته را فراهم کرده‌اند و در کاربردهایی مانند تحلیل گزارش‌های مالی، استخراج اطلاعات، پاسخ‌گویی به پرسش‌ها و استدلال مالی مورد استفاده قرار گرفته‌اند [۱]. با این حال، مطالعات موجود نشان می‌دهند که این مدل‌ها همچنان در استدلال چندمرحله‌ای، استفاده صحیح از شواهد و مدیریت اطلاعات مشابه یا گمراه‌کننده با چالش مواجه هستند [۱].

این محدودیت‌ها در اسناد مالی اهمیت ویژه‌ای دارند، زیرا معمولاً چندین مقدار عددی نزدیک به یکدیگر با توضیحات و قیود متفاوت در یک زمینه مشترک ظاهر می‌شوند. بنابراین، ارزیابی مدل‌های زبانی در این حوزه باید علاوه بر صحت پاسخ نهایی، توانایی مدل در انتخاب مقدار متناظر با اطلاعات معنایی درخواست‌شده را نیز مورد توجه قرار دهد.

۲-۴- پرسش و پاسخ مالی و بنچمارک‌های مرتبط

پرسش و پاسخ مالی یکی از مسائل مهم در درک اسناد مالی است که در آن مدل باید با استفاده از متن، جدول یا ترکیبی از هر دو، پاسخ مناسب را استخراج یا استنتاج کند. برخلاف وظایف عمومی پرسش و پاسخ، در این حوزه معمولاً مدل با اعداد، واحدها، سال‌ها، مفاهیم حسابداری و روابط میان بخش‌های مختلف یک سند مالی مواجه است. از این رو، پاسخ صحیح می‌تواند نیازمند ترکیبی از درک متن، انتخاب شواهد مناسب و استدلال عددی باشد.

۲-۴-۱ بنچمارک FinQA

بنچمارک FinQA با هدف ارزیابی استدلال عددی بر روی گزارش‌های مالی طراحی شده است [۲]. نمونه‌های این مجموعه شامل پرسش‌هایی هستند که پاسخ به آن‌ها معمولاً با استفاده از اطلاعات متنی و جدولی و اجرای چند مرحله عملیات عددی به دست می‌آید. یکی از ویژگی‌های FinQA ارائه برنامه استدلال یا زنجیره عملیاتی برای تولید پاسخ نهایی است.

اگرچه FinQA امکان بررسی توانایی مدل در استدلال عددی مالی را فراهم می‌کند، پاسخ نادرست در آن می‌تواند ناشی از عوامل مختلفی مانند انتخاب شواهد اشتباه، استخراج مقدار نادرست یا اجرای محاسبه نادرست باشد. بنابراین، این بنچمارک به‌طور خاص برای جداکردن خطای اتصال قید به مقدار طراحی نشده است.

۲-۴-۲ بنچمارک TAT-QA

مجموعه TAT-QA مسئله پرسش و پاسخ بر روی محتوای ترکیبی متن و جدول را بررسی می‌کند [۳]. در این بنچمارک، پاسخ به برخی پرسش‌ها مستقیماً از سند استخراج می‌شود و برخی دیگر به انجام عملیات عددی بر روی اطلاعات موجود در متن و جدول نیاز دارند.

وجود هم‌زمان متن و جدول، TAT-QA را به محیطی مناسب برای ارزیابی درک اسناد مالی تبدیل می‌کند. با این حال، همانند FinQA، خطاهای مدل در این مجموعه می‌توانند حاصل ترکیبی از مشکلات استخراج، انتخاب شواهد، استدلال یا محاسبه باشند؛ در نتیجه، نوع خاص خطای انتخاب مقدار بر اساس قید به‌صورت مستقل ایزوله نمی‌شود.

۲-۴-۳ بنچمارک FinanceBench

FinanceBench توسط اسلام و همکاران^۱ با هدف ارزیابی مدل‌های زبانی بزرگ در پرسش‌وپاسخ مالی مبتنی بر اسناد واقعی شرکت‌ها ارائه شده است [۴]. این بنچمارک شامل پرسش‌هایی درباره شرکت‌های عمومی و اسناد مالی واقعی است و برای هر پرسش، پاسخ و شواهد مرتبط نیز در نظر گرفته شده است. نسخه کامل آن شامل ۱۰۶۳۱ پرسش است و نمونه متن‌باز مورد استفاده در ارزیابی مقاله شامل ۱۵۰ مورد برچسب‌گذاری شده است.

اهمیت FinanceBench برای این پایان‌نامه در آن است که محیط آن به کاربردهای واقعی پرسش‌وپاسخ مالی نزدیک‌تر است و بر توانایی مدل در یافتن و استفاده از شواهد صحیح در اسناد مالی تأکید دارد. با این حال، هدف اصلی آن ارزیابی عمومی عملکرد مدل‌های زبانی در پرسش و پاسخ در حوزه مالی است و ساختار آن برای مطالعه کنترل‌شده یک خطای مشخص مانند انتخاب مقدار متعلق به قید رقیب طراحی نشده است.

۲-۵-۵ مفاهیم و انواع خطاهای مرتبط

برای مشخص کردن جایگاه مسئله مورد مطالعه در این پایان‌نامه، لازم است میان چند نوع خطای نزدیک اما متفاوت تمایز قائل شد. این تمایز اهمیت دارد، زیرا یک پاسخ نادرست می‌تواند ناشی از بازیابی شواهد نامناسب، محاسبه اشتباه، تولید اطلاعات فاقد پشتوانه یا انتخاب یک مقدار معتبر اما متعلق به قید نادرست باشد.

۲-۵-۱ توهم

توهم به حالتی اشاره دارد که مدل اطلاعاتی تولید می‌کند که از زمینه یا منبع ارائه‌شده پشتیبانی نمی‌شود [۵]. در مسئله مورد مطالعه این پایان‌نامه، خطای WQSV با این حالت متفاوت است؛ زیرا مقدار انتخاب‌شده توسط مدل در همان منبع وجود دارد، اما به قید مورد درخواست پرسش تعلق ندارد. بنابراین، مسئله اصلی نبود پشتوانه برای مقدار نیست، بلکه ارتباط نادرست میان مقدار و قید است.

۲-۵-۲ خطای بازیابی و انتخاب شواهد

در سامانه‌های پرسش‌وپاسخ مبتنی بر اسناد، یکی از منابع مهم خطای بازیابی بخش نامرتبط یا انتخاب شواهد نامناسب است. پژوهش‌های اخیر در پرسش‌وپاسخ مالی نیز نشان داده‌اند که تشخیص شواهد مربوط به

^۱ Islam et al.

شرکت، دوره گزارش‌دهی و زمینه مورد نظر می‌تواند خود یک مسئله مستقل باشد. برای مثال، چو و همکاران^۱ در LOFin بر بازیابی و پالایش شواهد از اسناد مالی گسترده تمرکز کرده‌اند [۱۵]. در مقابل، فین‌اسکوپ در حالت کنترل‌شده فرض می‌کند زمینه مورد نیاز از قبل در اختیار مدل قرار گرفته و مقدار هدف و مقادیر رقیب در همان زمینه حضور دارند. بنابراین، هدف اصلی آن ارزیابی کیفیت بازیابی سند نیست، بلکه بررسی انتخاب مقدار صحیح پس از فراهم‌شدن زمینه مرتبط است.

۲-۵-۳ خطای استدلال عددی

نوع دیگری از خطا می‌تواند پس از انتخاب مقادیر صحیح و در مرحله انجام عملیات عددی رخ دهد. FinQA و TAT-QA نمونه‌هایی از بنچمارک‌هایی هستند که بخش مهمی از پرسش‌های آن‌ها به جمع، تفریق، تقسیم، مقایسه یا ترکیب چند عملیات نیاز دارد [۲]، [۳]. خطای WQSV با خطای استدلال عددی متفاوت است. در WQSV، مسئله می‌تواند پیش از هرگونه محاسبه رخ دهد؛ مدل از میان چند مقدار موجود، مقداری را انتخاب می‌کند که از نظر عددی معتبر است اما با قید مورد درخواست مطابقت ندارد.

۲-۵-۴ اتصال ویژگی به مقدار

مسئله اتصال موجودیت یا ویژگی به مقدار، در مطالعات عمومی مدل‌های زبانی نیز مورد توجه قرار گرفته است. دای و همکاران^۲ نشان داده‌اند که مدل‌های زبانی برای ردیابی صحیح اطلاعات باید بتوانند موجودیت‌ها را به ویژگی‌های متناظر آن‌ها متصل کنند [۱۶]. مفهوم اتصال قید به مقدار در این پایان‌نامه از نظر کلی با این خانواده از مسائل مرتبط است، اما دامنه آن محدودتر و مالی است. در فین‌اسکوپ، تمرکز بر شرایطی است که چند مقدار معتبر در یک زمینه وجود دارند و هرکدام به یک قید مالی متفاوت وابسته‌اند. مدل باید مقدار متناظر با قید مورد درخواست را انتخاب کند.

۲-۶- شکاف پژوهشی

بررسی بنچمارک‌های پرسش و پاسخ‌های حوزه مالی و انواع خطاهای مرتبط نشان می‌دهد که پژوهش‌های موجود جنبه‌های مختلفی مانند استدلال عددی، بازیابی شواهد، پرسش‌وپاسخ بر متن و جدول و

^۱ Choe et al.

^۲ Dai et al.

اتصال پاسخ به شواهد منبع^۱ را بررسی کرده‌اند [۲]–[۴]، [۱۵]. با این حال، این مسائل معمولاً چندین منبع خطا را به صورت هم‌زمان در برمی‌گیرند و پاسخ نادرست لزوماً مشخص نمی‌کند که مدل در انتخاب شواهد، محاسبه یا تطبیق معنایی مقدار با پرسش دچار مشکل شده است.

شکاف مورد توجه این پایان‌نامه، کمبود ارزیابی‌های کنترل‌شده‌ای است که به‌طور مشخص انتخاب مقدار حساس به قید را از سایر منابع خطا جدا کنند؛ محیطی که در آن قید هدف، مقدار هدف و مقادیر معتبر متعلق به قیود رقیب به صورت صریح مشخص باشند. هدف فین‌اسکوپ پرکردن همین شکاف و فراهم کردن امکان تشخیص خطای WQSV به صورت مستقل از خطاهای عمومی‌تر است.

۷-۲- جمع‌بندی

در این فصل، ابتدا چشم‌انداز کلی کاربرد هوش مصنوعی در حوزه مالی و مسیرهای عددی، متنی، تصویری و چندوجهی مرور شد. سپس تمرکز به مسائل درک و استدلال مالی و بنچمارک‌های پرسش و پاسخ مالی منتقل شد. در ادامه، تفاوت مسئله مورد مطالعه با توهم، خطای بازیابی، انتخاب شواهد و خطای استدلال عددی بررسی گردید. بر اساس این پیشینه، نیاز به یک محیط کنترل‌شده برای ارزیابی اتصال صحیح قیود مالی به مقادیر متناظر مشخص شد. در فصل بعد، طراحی، ساخت و اعتبارسنجی فین‌اسکوپ برای مطالعه این مسئله تشریح خواهد شد.

¹ Grounding

فصل سوم

شرح پروژه

۳-۱- مقدمه

در فصل‌های پیشین، مسئله انتخاب مقدار حساس به قید در داده‌های مالی و جایگاه آن در میان مسائل درک و پرسش‌وپاسخ مالی بررسی شد. همان‌طور که بیان شد، در بسیاری از اسناد مالی چند مقدار معتبر به‌طور هم‌زمان وجود دارند که هرکدام به سال، مبنای ارائه، مبنای ارزی، دامنه گزارش‌دهی یا وضعیت متفاوتی وابسته‌اند. در چنین شرایطی، پاسخ صحیح صرفاً با شناسایی یک عدد موجود در سند تعیین نمی‌شود، بلکه مدل باید مقدار متناظر با قید یا مجموعه قیود مطرح‌شده در پرسش را انتخاب کند.

بر این اساس، در این پروژه بنچمارک فین‌اسکوپ با هدف مطالعه کنترل‌شده این مسئله طراحی و توسعه داده شد. طراحی فین‌اسکوپ بر این اصل استوار است که در هر نمونه، قید هدف، مقدار صحیح و مقادیر معتبر متعلق به قیود رقیب به‌صورت صریح قابل شناسایی باشند. این ساختار امکان می‌دهد خطایی که در آن مدل به‌جای مقدار هدف، یکی از مقادیر موجود اما متعلق به قید رقیب را انتخاب می‌کند، به‌صورت مستقل بررسی شود.

فرایند توسعه فین‌اسکوپ شامل چند مرحله اصلی بوده است. ابتدا مسئله و تعریف عملیاتی خطای مورد مطالعه مشخص شد و خانواده‌های اصلی قیود مالی مورد استفاده در بنچمارک سازمان‌دهی شدند. سپس نمونه‌های مصنوعی در چند نسخه متوالی طراحی شدند تا کنترل بیشتری بر ساختار داده، مقادیر رقیب و نشانه‌های سطحی احتمالی فراهم شود. در کنار این بخش، مجموعه‌ای از نمونه‌های مبتنی بر داده‌های واقعی مالی نیز ایجاد شد تا وجود این نوع ابهام در داده‌های واقعی بررسی شود.

پس از ساخت داده‌ها، فرایندهای اعتبارسنجی خودکار و انسانی برای بررسی صحت نگاشت میان قیدها و مقادیر، سازگاری ساختاری نمونه‌ها و کنترل خطاهای احتمالی انجام شد. همچنین آزمون‌هایی برای شناسایی میان‌برهای سطحی و نشت اطلاعات در طراحی بنچمارک در نظر گرفته شد. در ادامه، زیرساختی برای نرمال‌سازی پاسخ مدل‌ها، امتیازدهی و تفکیک خروجی‌ها به دسته‌های مختلف توسعه یافت.

در این فصل، ابتدا صورت‌بندی مسئله و تعاریف مورد استفاده ارائه می‌شود. سپس نحوه استخراج خانواده‌های قیدی، طراحی نسخه‌های مختلف داده‌های مصنوعی و بخش واقعی فین‌اسکوپ تشریح خواهد شد. در ادامه، مراحل اعتبارسنجی و کنترل کیفیت و در نهایت سازوکار ارزیابی و مشخصات نسخه نهایی بنچمارک ارائه می‌شوند.

۳-۲- صورت‌بندی مسئله و تعاریف

۳-۲-۱ انتخاب مقدار حساس به قید

در بسیاری از اسناد مالی، برای یک شاخص واحد چند مقدار معتبر به‌طور هم‌زمان گزارش می‌شود. تفاوت این مقادیر ممکن است ناشی از سال، مبنای ارائه، مبنای ارزی، دامنه گزارش‌دهی یا وضعیت راهنمایی و عملکرد باشد. در چنین شرایطی، انتخاب پاسخ صحیح تنها به یافتن یک مقدار عددی در متن محدود نمی‌شود، بلکه مدل باید مقدار متناظر با قید مورد درخواست را شناسایی کند. در این پژوهش، این مسئله با عنوان انتخاب مقدار حساس به قید توصیف می‌شود. منظور از آن، انتخاب مقدار صحیح از میان چند مقدار معتبر بر اساس ویژگی یا قید معنایی مشخص‌شده در پرسش است.

۳-۲-۲ اتصال قید به مقدار

برای صورت‌بندی دقیق‌تر مسئله، از مفهوم اتصال قید به مقدار استفاده می‌شود. در این مفهوم، هر مقدار مالی به یک یا چند قید معنایی وابسته است و مدل باید این ارتباط را به‌درستی حفظ کند. به‌صورت مفهومی، اگر q قید درخواست‌شده و v_q مقدار متناظر با آن باشد، هدف مدل انتخاب نگاشت صحیح زیر است:

$$q \rightarrow v_q$$

در مقابل، انتخاب مقدار v_z که به قید دیگری q_z تعلق دارد، نشان‌دهنده خطا در اتصال قید به مقدار است.

۳-۲-۳ تعریف خطای WQSV

در فین‌اسکوپ، حالتی که مدل به‌جای مقدار هدف، یک مقدار معتبر و موجود در همان منبع را انتخاب کند که به یک قید غیرهدف تعلق دارد، با عنوان مقدار منبع با قید نادرست تعریف می‌شود.

به‌صورت عملیاتی، یک پاسخ زمانی در گروه WQSV قرار می‌گیرد که:

۱. پاسخ با مقدار صحیح هدف مطابقت نداشته باشد؛

۲. مقدار تولیدشده در منبع یا زمینه ارائه شده وجود داشته باشد؛
 ۳. مقدار تولیدشده با مقدار متعلق به یکی از قیود غیرهدف مطابقت داشته باشد .
- بنابراین، WQSV با پاسخ‌های کاملاً ساختگی یا مقادیری که در منبع وجود ندارند متفاوت است. این تعریف مستقیماً در سازوکار امتیازدهی فین‌اسکوپ پیاده‌سازی شده است.

۴-۲-۳ انواع خروجی در فین‌اسکوپ

- سازوکار امتیازدهی فین‌اسکوپ خروجی مدل را در یکی از چهار گروه اصلی قرار می‌دهد:
۱. CORRECT: پاسخ با مقدار هدف مطابقت دارد.
 ۲. WQSV: پاسخ با مقدار معتبر متعلق به یک قید غیرهدف مطابقت دارد.
 ۳. OTHER_WRONG: پاسخ معتبر است، اما نه با مقدار هدف و نه با مقادیر رقیب مطابقت دارد.
 ۴. INVALID: خروجی قابل تفسیر به‌عنوان یک پاسخ عددی معتبر نیست.
- این تفکیک باعث می‌شود خطای اتصال قید به مقدار از سایر پاسخ‌های نادرست جداگانه بررسی شود.

۳-۳ استخراج و سازمان‌دهی خانواده‌های قیدی

برای مطالعه نظام‌مند مسئله اتصال قید به مقدار، مجموعه‌ای از خانواده‌های قیدی در فین‌اسکوپ تعریف شده است. در نسخه نهایی بنچمارک، چهار خانواده اصلی مورد استفاده قرار گرفته‌اند:

۱. مبنای ارائه
 ۲. مبنای ارزی
 ۳. موقعیت راهنمایی یا عملکرد
 ۴. دامنه گزارش‌دهی
- این چهار خانواده، ساختار و روش^۱ عملیاتی مورد استفاده در فین‌اسکوپ را تشکیل می‌دهند و نباید به‌عنوان یک طبقه‌بندی جامع از تمام قیود موجود در اسناد مالی تفسیر شوند.

¹ Taxonomy

۳-۳-۱ مبنای ارائه

خانواده مبنای ارائه به شرایطی مربوط است که یک شاخص مالی بر اساس بیش از یک مبنای گزارش یا ارائه بیان می‌شود. نمونه متداول آن تفاوت میان مقادیر گزارش شده بر اساس اصول رسمی حسابداری و مقادیر تعدیل شده است.

در این حالت، مدل باید تشخیص دهد پرسش دقیقاً کدام مبنا را درخواست کرده و مقدار متناظر با همان مبنا را انتخاب کند.

۳-۳-۲ مبنای ارزی

خانواده مبنای ارزی شامل مواردی است که یک مقدار مالی بر اساس شرایط متفاوت ارزی گزارش می‌شود. برای مثال، ممکن است یک شاخص هم بر اساس نرخ ارز گزارش شده و هم بر اساس نرخ ارز ثابت ارائه شود.

در چنین مواردی، تفاوت میان مقادیر ناشی از تفاوت در مبنای ارزی است و انتخاب مقدار صحیح به تشخیص دقیق این قید وابسته است.

۳-۳-۳ موقعیت راهنمایی یا عملکرد

خانواده موقعیت راهنمایی یا عملکرد به شرایطی مربوط است که چند مقدار مرتبط با راهنمایی، عملکرد یا موقعیت یک مقدار در یک بازه گزارش می‌شوند.

نمونه‌هایی از این حالت شامل حد پایین، حد بالا، مقدار میانی یا نقش‌های متفاوت یک مقدار در سناریوهای راهنمایی مالی است. در این موارد، مدل باید موقعیت یا نقش مورد درخواست را به مقدار صحیح مرتبط کند.

۳-۳-۴ دامنه گزارش‌دهی

خانواده دامنه گزارش‌دهی شرایطی را شامل می‌شود که یک شاخص مالی برای دامنه‌های سازمانی یا جغرافیایی متفاوت گزارش شده باشد؛ برای مثال مقدار مربوط به کل شرکت در مقابل یک بخش تجاری مشخص.

در این حالت، مقدارها ممکن است همگی از نظر عددی معتبر باشند، اما تنها مقداری که به دامنه مورد درخواست پرسش تعلق دارد پاسخ صحیح محسوب می‌شود.

۳-۴- طراحی و ساخت فین اسکوپ

فین اسکوپ از دو بخش اصلی تشکیل شده است: داده‌های مصنوعی کنترل شده و نمونه‌های مبتنی بر داده‌های واقعی مالی. هدف از این طراحی، ترکیب کنترل آزمایشگاهی با شواهد برگرفته از داده‌های واقعی بوده است. بخش مصنوعی امکان کنترل دقیق قیدها و مقادیر رقیب را فراهم می‌کند، در حالی که بخش واقعی نشان می‌دهد این نوع ابهام در اسناد مالی واقعی نیز رخ می‌دهد.

۳-۴-۱ ساختار کلی یک پیکربندی

هر پیکربندی^۱ در فین اسکوپ شامل یک زمینه مالی و حداقل دو حالت قیدی رقیب است. برای هر قید، یک مقدار متناظر در نظر گرفته می‌شود. سپس دو پرسش متقابل ساخته می‌شود که هر کدام یکی از قیدها را هدف قرار می‌دهند.

به این دو پرسش متقابل، **دوقلو**^۲ گفته می‌شود. در دوقلو اول، مقدار A پاسخ صحیح و مقدار B مقدار رقیب است؛ در دوقلو دوم این نقش‌ها برعکس می‌شوند. این ساختار کمک می‌کند مدل نتواند تنها بر اساس موقعیت یا خود مقدار، بدون توجه به قید پرسش، پاسخ دهد.

ساختار مفهومی هر پیکربندی را می‌توان به صورت زیر در نظر گرفت:

$$(Q_A \rightarrow V_A), (Q_B \rightarrow V_B)$$

که در آن Q_A و Q_B دو قید رقیب و V_A و V_B مقادیر متناظر با آن‌ها هستند.

۳-۴-۲ نسخه مصنوعی ورژن V1

نسخه V1 نخستین نسخه کنترل شده داده‌های مصنوعی فین اسکوپ است. این نسخه شامل:

• ۱۶۰ پیکربندی

• ۳۲۰ سوال

است.

در V1، ساختار پایه مسئله اتصال قید به مقدار و طراحی دوقلوها تثبیت شد. با این حال، بررسی‌های بعدی نشان داد برخی نشانه‌های سطحی، به ویژه موقعیت مقدارها در متن، می‌توانند به عنوان میان‌بر مورد استفاده قرار گیرند.

¹ Configuration

² Twin

۳-۴-۳ نسخه مصنوعی ورژن V2

نسخه V2 با هدف کاهش برخی از الگوهای سطحی مشاهده شده در V1 طراحی شد. این نسخه شامل:

- ۳۲۰ پیکربندی
- ۶۴۰ سوال

است.

در این مرحله، تنوع بیشتری در نحوه نمایش قیدها و مقادیر ایجاد شد و ساختار نمونه‌ها نسبت به V1 اصلاح گردید. هدف V2 افزایش کنترل بر میانبر^۱های احتمالی بود، نه تعریف یک سطح دشواری بالاتر.

۳-۴-۴ نسخه مصنوعی ورژن V3

نسخه V3 مرحله بعدی تکامل طراحی داده‌های مصنوعی فین‌اسکوپ است و شامل:

- ۲۴۰ پیکربندی
- ۴۸۰ سوال

می‌شود.

در این نسخه، تنوع سطحی و نحوه بیان قیدها بیشتر شد تا وابستگی مدل به تطابق مستقیم واژگان کاهش یابد. با این حال، این سه نسخه به‌عنوان سطوح دشواری تعریف نشده‌اند و تفاوت آن‌ها بیشتر بیانگر مراحل اصلاح طراحی بنچمارک است.

۳-۴-۵ بخش مبتنی بر نمونه‌های واقعی

در کنار داده‌های مصنوعی، یک بخش دیتای واقعی^۲ نیز در فین‌اسکوپ در نظر گرفته شده است. نسخه نهایی این بخش شامل:

- ۱۳۶ پیکربندی
- ۲۷۲ سوال

است.

نمونه‌های این بخش از منابع و بنچمارک‌های مالی واقعی استخراج و سپس برای مسئله اتصال قید به مقدار بازبینی و اعتبارسنجی شده‌اند. در این نمونه‌ها نیز برای هر پیکربندی دو مقدار رقیب و دو پرسش متقابل وجود دارد.

¹ Shortcut

² Real-World

هدف این بخش اثبات شیوع پدیده در کل اسناد مالی نیست، بلکه نشان دادن این موضوع است که مسئله انتخاب مقدار حساس به قید صرفاً حاصل داده‌های مصنوعی نیست و در نمونه‌های واقعی نیز قابل مشاهده است .

۳-۴-۶ اندازه و ترکیب مجموعه داده

مشخصات نسخه نهایی فین‌اسکوپ در جدول ۳-۱ زیر خلاصه شده است:

جدول ۳-۱: تعداد پیکربندی‌ها و پرسش‌ها در بخش‌های مختلف فین‌اسکوپ

بخش	تعداد پیکربندی	تعداد سوال
V1	۱۶۰	۳۲۰
V2	۳۲۰	۶۴۰
V3	۲۴۰	۴۸۰
مجموع مصنوعی	۷۲۰	۱۴۴۰
دیتای واقعی	۱۳۶	۲۷۲
مجموع نهایی	۸۵۶	۱۷۱۲

۳-۵-۱ اعتبارسنجی و کنترل کیفیت

پس از ساخت داده‌ها، چند مرحله اعتبارسنجی برای بررسی سازگاری ساختاری، صحت نگاشت قیدها و مقادیر، شناسایی میان‌برها و کنترل نشت اطلاعات انجام شد.

۳-۵-۱ اعتبارسنجی خودکار

در اعتبارسنجی خودکار مواردی مانند موارد زیر بررسی شدند:

- یکتا بودن شناسه پیکربندی و سوال
- وجود دقیق دو پرسش برای هر پیکربندی
- سازگاری میان سوال، پاسخ طلایی^۱ و ورودی در قالب پرامپت
- صحت نگاشت دوقلوهای متقابل

^۱ Gold Answer

- تطابق ساختار دفتر ثبت امتیازدهی^۱ با داده اصلی
- در نسخه نهایی، ۸۵۶ شناسه پیکربندی و ۱۷۱۲ شناسه سوال یکتا هستند و هیچ شناسه تکراری گزارش نشده است.

۳-۵-۲ اعتبارسنجی انسانی

برای بخشی از داده‌ها، فرایند اعتبارسنجی^۲ با کمک مدل و بازبینی انسانی انجام شد. در مجموع ۳۲۸ پیکربندی بررسی شدند که شامل تمام ۱۳۶ نمونه دیتای واقعی و ۱۹۲ نمونه مصنوعی بودند.

در مرحله اولیه:

- ۲۹۰ مورد معتبر
- ۳۸ مورد نامطمئن
- ۰ مورد نامعتبر

ثبت شد.

پس از رسیدگی^۳، از ۳۸ مورد نامطمئن:

- ۲۱ مورد تأیید شدند؛
 - ۱۷ مورد نیازمند اصلاح تشخیص داده شدند؛
 - هیچ پیکربندی حذف نشد .
- تمام ۱۷ مورد اصلاح‌شده پس از بازبینی مجدد، اعتبارسنجی را با موفقیت گذراندند .

۳-۵-۳ کنترل میان‌برها و نشت اطلاعات

برای بررسی اینکه مدل بتواند بدون توجه واقعی به قید از الگوهای سطحی استفاده نکند، چند گروه آزمون انجام شد، از جمله:

- میانبر موقعیتی
- میانبر واژگانی
- میانبر مبتنی بر بزرگی مقدار
- الگوهای ساختاری
- نشت میان بخش‌ها

^۱ Scorer Ledger

^۲ Validation

^۳ Adjudication

در بررسی نهایی، هیچ تکرار دقیق میان بخش‌ها برای سوال و یا پیکربندی گزارش نشد.

۳-۵-۴ تثبیت نسخه نهایی

پس از اعمال اصلاحات، نسخه نهایی بنچمارک بدون افزودن یا حذف پیکربندی تثبیت شد. تعداد نهایی همچنان ۸۵۶ پیکربندی و ۱۷۱۲ سوال باقی ماند و ۱۷ نمونه اصلاح شده نیز مجدداً اعتبارسنجی را با موفقیت گذراندند.

۳-۶-۲ زیرساخت ارزیابی

برای ارزیابی خروجی مدل‌ها در فین‌اسکوپ، یک زیرساخت ارزیابی مستقل و نسخه‌بندی شده توسعه داده شده است. این زیرساخت شامل نرمال‌سازی پاسخ، امتیازدهی تشخیصی، اجرای مدل‌ها و ثبت خروجی‌ها به صورت بازتولیدپذیر است. نسخه نهایی امتیازدهنده^۱ برابر با **v1.0.1** است و همراه با نرمال‌ساز^۲ و اجراکننده‌های^۳ ارزیابی در ساختار پروژه نگهداری می‌شود.

۳-۶-۱ نرمال‌سازی پاسخ‌ها

خروجی خام مدل‌ها ممکن است از نظر نمایش عددی با پاسخ مرجع تفاوت داشته باشد؛ برای مثال یک مقدار می‌تواند با جداکننده هزارگان، نماد ارز، درصد، علامت منفی یا مقیاس‌هایی مانند میلیون و میلیارد نوشته شود. برای کاهش اثر این تفاوت‌های ظاهری، پیش از امتیازدهی از نرمال‌ساز استفاده می‌شود. نرمال‌ساز نسخه نهایی فین‌اسکوپ مواردی مانند موارد زیر را پردازش می‌کند:

- اعداد صحیح و اعشاری
- جداکننده‌های عددی
- درصد و نقطه پایه^۴
- نمادها و کدهای رایج ارز
- نمایش حسابداری اعداد منفی با پرانتز
- مقیاس‌هایی مانند هزار، میلیون و میلیارد
- خروجی‌های خالی، امتناع از پاسخ و پاسخ‌های دارای چند عدد

پس از نرمال‌سازی، مقدار متعارف^۵ خروجی مدل با مقدار مرجع مقایسه می‌شود. در نسخه فعلی،

^۱ Scorer

^۲ Normalizer

^۳ Runner

^۴ Basis Point

تلورانس عددی تقریبی استفاده نمی‌شود و مقایسه پس از نرمال‌سازی بر اساس برابری دقیق مقدار انجام می‌شود. همچنین واحدهایی مانند درصد و واحد پایه به صورت واحدهای مجزا در نظر گرفته می‌شوند و به‌طور خودکار به یکدیگر تبدیل نمی‌شوند.

۳-۶-۲- سازوکار امتیازدهی

پس از نرمال‌سازی، امتیازدهنده پاسخ مدل را با مقدار هدف و مقادیر مربوط به قیود غیرهدف مقایسه می‌کند. فرایند کلی به این صورت است که ابتدا بررسی می‌شود آیا پاسخ با مقدار هدف مطابقت دارد یا خیر. اگر پاسخ صحیح نباشد، مقدار تولیدشده با مقادیر معتبر متعلق به قیود رقیب مقایسه می‌شود. بر این اساس، چهار برچسب اصلی تولید می‌شود:

- CORRECT
- WQSV
- OTHER_WRONG
- INVALID

اگر پاسخ با مقدار هدف مطابقت داشته باشد، CORRECT ثبت می‌شود. اگر پاسخ نادرست باشد اما با یکی از مقادیر معتبر متعلق به قید غیرهدف مطابقت داشته باشد، برچسب WQSV اختصاص داده می‌شود. پاسخ‌های معتبر دیگری که در هیچ‌یک از این دو گروه قرار نگیرند OTHER_WRONG و خروجی‌های غیرقابل تفسیر INVALID محسوب می‌شوند.

۳-۶-۳- اطلاعات تشخیصی خروجی

دفتر امتیازات علاوه بر برچسب اصلی، اطلاعات تشخیصی دیگری نیز برای هر پرسش ثبت می‌کند. از مهم‌ترین این اطلاعات می‌توان به موارد زیر اشاره کرد:

- قید درخواست‌شد
- قیود غیرهدف
- مقادیر متعلق به قیود غیرهدف
- قید یا قیودی که پاسخ مدل با آن‌ها مطابقت داشته است
- مقادیر غیرهدف تطبیق‌یافته

- وضعیت تجزیه‌کننده^۱ و فرایند نرمال‌سازی
 - شاخص تشخیص خطای اتصال قید به مقدار
- به این ترتیب، ارزیابی تنها به محاسبه دقت^۲ محدود نمی‌شود و امکان تحلیل نوع خطای مدل نیز فراهم می‌شود. در فین‌اسکوپ، متغیر IS_BINDING_ERROR زمانی فعال می‌شود که پاسخ مدل به‌عنوان WQSV شناسایی شده باشد.

۳-۶-۴- پروتکل اجرای ارزیابی و بازتولیدپذیری

زیرساخت ارزیابی فین‌اسکوپ شامل اجراکننده‌های اجرای مدل، ثبت و تایید مدل‌ها، تنظیمات رمزگشایی^۳، اعتبارسنجی ورودی و خروجی و فایل‌های مشخصات^۴ بازتولیدپذیری است. همچنین امتیازدهنده امکان دریافت مستقیم فایل پیش‌بینی خارجی را دارد؛ به‌گونه‌ای که هر خروجی با شناسه پرسش و پاسخ خام مدل ثبت و سپس به‌صورت یکسان نرمال‌سازی و امتیازدهی می‌شود.

ساختار حداقلی هر پیش‌بینی شامل شناسه پرسش و خروجی خام مدل است:

```
{"QUESTION_ID": "...", "RAW_MODEL_OUTPUT": "..."}

```

این طراحی باعث می‌شود نتایج مدل‌های مختلف با یک امتیازدهنده و نرمال‌ساز ثابت ارزیابی شوند و تفاوت نتایج ناشی از تغییر در منطق امتیازدهی نباشد.

برای افزایش بازتولیدپذیری، نسخه بنچمارک، امتیازدهنده، نرمال‌ساز و پروتکل^۵ ارزیابی به‌صورت مستقل ثبت شده‌اند. نسخه‌های مورد استفاده در release نهایی عبارت‌اند از:

- **FinScope Benchmark: v1.1.1**
- **Scorer: v1.0.1**
- **Normalizer: v1.0.1**
- **Evaluation Protocol: v1.0**

این ساختار امکان اجرای مجدد آزمایش‌ها و مقایسه مدل‌ها یا نسخه‌های مختلف یک مدل را تحت شرایط ارزیابی ثابت فراهم می‌کند.

¹ Parser

² Accuracy

³ Decoding

⁴ Reproducibility Manifest

⁵ Protocol

۳-۷- مشخصات نسخه نهایی فین اسکوپ

پس از مراحل طراحی، اصلاح، اعتبارسنجی و تثبیت داده‌ها، نسخه نهایی بنچمارک با عنوان **فین اسکوپ v1.1.1-FINAL_FROZEN** ثبت شد. این نسخه شامل هر سه بخش مصنوعی V1، V2 و V3 و همچنین بخش Real-World است.

مشخصات اصلی نسخه نهایی در جدول ۳-۲ زیر ارائه شده است:

جدول ۳-۲: مشخصات نسخه نهایی و اجزای ارزیابی فین اسکوپ

نسخه / مقدار	مؤلفه
FinScope v1.1.1	نسخه نهایی داده
FINAL_FROZEN	وضعیت انتشار
۸۵۶	تعداد کل پیکربندی
۱۷۱۲	تعداد کل سوال
۷۲۰	تعداد پیکربندی مصنوعی
۱۴۴۰	تعداد سوال مصنوعی
۱۳۶	تعداد پیکربندی واقعی
۲۷۲	تعداد سوال واقعی
v1.0.1	نسخه امتیازدهنده
v1.0.1	نسخه نرمال ساز
v1.0	نسخه پروتکل ارزیابی
۴	تعداد خانواده‌های قیدی

ساختار نهایی بنچمارک به گونه‌ای تثبیت شده است که شناسه‌های پیکربندی و سوال یکتا باشند و ارتباط میان داده‌های ورودی، پاسخ‌های مرجع و امتیازدهنده حفظ شود. همچنین پس از اصلاح نمونه‌های نیازمند بازبینی، هیچ پیکربندی جدیدی افزوده یا حذف نشد و تعداد نهایی مجموعه ثابت باقی ماند. نسخه نهایی داده، امتیازدهنده و نرمال ساز به صورت نسخه‌بندی شده نگهداری شده‌اند تا آزمایش‌های فصل بعد بر مبنای یک مجموعه و سازوکار امتیازدهی ثابت انجام شوند.

۳-۸- جمع‌بندی

در این فصل، طراحی و توسعه فین‌اسکوپ به‌عنوان یک بنچمارک کنترل‌شده برای مطالعه مسئله انتخاب مقدار حساس به قید تشریح شد. ابتدا صورت‌بندی مسئله و مفاهیم QVB و WQSV ارائه شدند و سپس چهار خانواده قیدی مورد استفاده در فین‌اسکوپ معرفی گردیدند.

در ادامه، ساختار بنچمارک شامل سه نسخه مصنوعی V1، V2 و V3 و بخش مبتنی بر نمونه‌های واقعی توضیح داده شد. همچنین مراحل اعتبارسنجی، بازبینی نمونه‌ها، کنترل میان‌برها و نشت اطلاعات و فرایند تثبیت نسخه نهایی تشریح شدند.

در بخش پایانی، زیرساخت ارزیابی شامل نرمال‌ساز، امتیازدهنده و پروتکل اجرای آزمایش معرفی شد. نسخه نهایی فین‌اسکوپ شامل ۸۵۶ پیکربندی و ۱۷۱۲ سوال است و امکان تفکیک پاسخ‌های مدل به چهار گروه CORRECT، WQSV، OTHER_WRONG و INVALID را فراهم می‌کند. در فصل بعد، تنظیمات آزمایش، مدل‌های مورد ارزیابی و نتایج تجربی حاصل از اجرای آن‌ها بر روی فین‌اسکوپ ارائه و تحلیل خواهند شد.

فصل چهارم

نتایج و ارزیابی

۴-۱- مقدمه

در فصل پیشین، ساختار مجموعه داده فین اسکوپ، نحوه طراحی پیکربندی‌ها و پرسش‌های دوقلو، فرایند اعتبارسنجی، سازوکار نرمال‌سازی پاسخ‌ها و منطق امتیازدهی تشریح شد. در این فصل، نتایج حاصل از ارزیابی تجربی مدل‌های منتخب ارائه و تحلیل می‌شود. هدف اصلی این ارزیابی، صرفاً مقایسه دقت نهایی مدل‌ها نیست، بلکه بررسی توانایی آن‌ها در انتخاب مقدار صحیح بر اساس قید مورد درخواست و تحلیل الگوی خطاهای مرتبط با اتصال قید به مقدار است.

زیرساخت ارزیابی فین اسکوپ برای آزمایش مجموعه گسترده‌تری از مدل‌های زبانی طراحی شده است و پنل ارزیابی کامل پروژه شامل هفت مدل است. با این حال، نتایج گزارش شده در این پایان‌نامه بر سه مدل منتخب گما-۲-۲بی-آی تی^۱، جی‌پی‌تی-اواس اس-۱۲۰بی^۲ و جی‌پی‌تی-۵،۶ سول^۳ متمرکز است. انتخاب این سه مدل امکان مقایسه رفتار یک مدل نسبتاً کوچک محلی با دو مدل توانمندتر را فراهم می‌کند. سایر مدل‌های پیش‌بینی شده در زیرساخت ارزیابی در مراحل تکمیلی پروژه و ارزیابی‌های بعدی مورد آزمایش قرار خواهند گرفت.

نتایج ارائه شده در این فصل حاصل آزمایش‌های تجربی انجام شده در مراحل مختلف توسعه فین اسکوپ هستند. از این رو، این نتایج نباید به عنوان رتبه‌بندی نهایی همه مدل‌ها روی نسخه نهایی مجموعه داده تلقی شوند. هدف از گزارش آن‌ها، تحلیل رفتار سه مدل منتخب، بررسی پایداری خطای انتخاب مقدار از قید نادرست و مطالعه تفاوت عملکرد در بخش‌های مختلف مجموعه داده است. ارزیابی جامع‌تر همه مدل‌ها بر روی تمام نسخه‌ها می‌تواند در ادامه پروژه انجام شود.

¹ Gemma-2-2B-IT

² GPT-OSS-120B

³ GPT-5.6 Sol

نسخه نهایی فریز شده فین اسکوپ شامل ۸۵۶ پیکربندی و ۱۰۷۱۲ پرسش است. از این تعداد، ۱۰۴۴۰ پرسش متعلق به سه بخش مصنوعی V1، V2 و V3 و ۲۷۲ پرسش متعلق به بخش داده‌های واقعی است. سه بخش مصنوعی به ترتیب شامل ۳۲۰، ۶۴۰ و ۴۸۰ پرسش هستند. لازم به تأکید است که این سه نسخه در این پایان‌نامه به عنوان سه مجموعه با طراحی متفاوت در نظر گرفته می‌شوند و ترتیب V1 تا V3 به معنای افزایش یکنواخت سطح دشواری نیست.

۲-۴- تنظیمات آزمایش

۴-۲-۱- مدل‌های مورد ارزیابی

آزمایش‌های گزارش شده در این فصل بر سه مدل انجام شده‌اند. مدل گما-۲-۲ بی-آی تی به صورت محلی و با استفاده از کتابخانه ترنسفورمر اجرا شده است، در حالی که دو مدل جی‌پی‌تی-اواس‌اس-۱۲۰ بی و جی‌پی‌تی-۵۶ سول از طریق رابط برنامه‌نویسی کاربردی^۱ مورد ارزیابی قرار گرفته‌اند. برای جلوگیری از وابستگی میان پرسش‌ها، هر پرسش به صورت مستقل به مدل ارائه شده است. به عبارت دیگر، هیچ تاریخچه مکالمه یا پاسخ قبلی در اختیار مدل قرار نگرفته است. همچنین مدل‌ها اجازه استفاده از جست‌وجوی وب، ابزار خارجی، ماشین حساب یا بازیابی اطلاعات خارج از شواهد ارائه شده در پرسش را نداشته‌اند.

جدول ۴-۱. مدل‌های منتخب مورد استفاده در ارزیابی تجربی

نقش در مقایسه	شیوه اجرا	مدل
مدل کوچک‌تر و پایه مقایسه	اجرای محلی	گما-۲-۲ بی-آی تی
مدل توانمند میانی	رابط برنامه‌نویسی کاربردی	جی‌پی‌تی-اواس‌اس-۱۲۰ بی
مدل توانمندتر در مجموعه آزمایش	رابط برنامه‌نویسی کاربردی	جی‌پی‌تی-۵۶ سول

در زیرساخت کامل پروژه، علاوه بر این سه مدل، مدل‌های دیگری نیز برای ارزیابی آینده در نظر گرفته شده‌اند. باین‌حال، برای حفظ تمرکز فصل و جلوگیری از ترکیب نتایج تکمیل شده با اجراهای آتی، تحلیل عددی حاضر صرفاً به سه مدل جدول ۴-۱ محدود شده است.

^۱ Application Programming Interface (API)

۴-۲-۲- تنظیمات تولید پاسخ

برای مدل‌های مبتنی بر رابط برنامه‌نویسی، هر پرسش در یک فراخوانی مستقل ارسال شده است. در مواردی که نقطه پایانی مدل از مقدار دمای صفر^۱ پشتیبانی می‌کرد، مقدار دما برابر صفر قرار داده شد تا میزان تصادفی‌بودن تولید کاهش یابد. حداکثر طول پاسخ برای مدل‌های میزبانی‌شده برابر ۲۰۴۸ توکن در نظر گرفته شده است.

برای مدل گما، تولید پاسخ به‌صورت حریصانه^۲ و بدون نمونه‌برداری تصادفی انجام شده است. مقدار max_new_tokens در اجرای این مدل برابر ۱۲۸ بوده است. اجرای مدل نیز در حالت استنتاج و با نوع داده bfloat16 انجام شده است.

در تمام اجراها تنها یک پاسخ معنایی برای هر پرسش در نظر گرفته شده است. تلاش مجدد فقط در صورت بروز خطاهای فنی مانند خطای محدودیت نرخ، قطع ارتباط یا شکست فراخوانی انجام شده و پاسخ معنایی نادرست باعث اجرای دوباره مدل نشده است. بنابراین سازوکار تلاش مجدد به‌عنوان فرصتی برای اصلاح پاسخ مدل عمل نکرده است.

جدول ۴-۲. تنظیمات اصلی تولید پاسخ در آزمایش‌ها

تنظیم	مدل‌های مبتنی بر رابط برنامه‌نویسی	گما-۲-بی-آی‌تی
تعداد پاسخ معنایی برای هر پرسش	۱	۱
دما	۰ در صورت پشتیبانی	بدون نمونه‌برداری
بیشینه طول تولید	۲۰۴۸ توکن	۱۲۸ توکن
استقلال پرسش‌ها	بله	بله
استفاده از ابزار خارجی	خیر	خیر
استفاده از وب یا بازیابی خارجی	خیر	خیر
تلاش مجدد برای پاسخ معنایی غلط	خیر	خیر

^۱ Temperature

^۲ Greedy Decoding

۴-۲-۳- سیاست دستور ورودی

دستور ورودی^۱ فین اسکوپ به گونه‌ای طراحی شده است که مدل فقط از شواهد ارائه شده در همان پرسش استفاده کند و مقدار نهایی را بدون توضیح اضافی بازگرداند. در نتیجه، ارزیابی حاضر بر توانایی مدل در تشخیص ارتباط میان قید درخواست شده و مقدار متناظر آن متمرکز است و استفاده از دانش خارجی یا استدلال مبتنی بر منابع بیرونی در آن نقشی ندارد.

هر سؤال همچنین مستقل از پرسش دوقلوی خود ارائه شده است؛ بنابراین مدل نمی‌تواند از مشاهده پاسخ یکی از دو پرسش برای پاسخ به پرسش دیگر استفاده کند.

۴-۳- معیارهای ارزیابی

برای تحلیل عملکرد مدل‌ها، ارزیابی تنها به دقت پاسخ محدود نشده و چند معیار مکمل مورد استفاده قرار گرفته است. این معیارها امکان تفکیک پاسخ صحیح، خطای اتصال قید به مقدار و سایر انواع پاسخ نادرست را فراهم می‌کنند.

۴-۳-۱- دقت

دقت^۲ برابر نسبت تعداد پاسخ‌های صحیح به کل پرسش‌های ارزیابی شده است:

$$Accuracy = \frac{N_{Correct}}{N}$$

که در آن N تعداد کل پرسش‌ها و $N_{Correct}$ تعداد پاسخ‌هایی است که پس از نرمال‌سازی با پاسخ مرجع مطابقت دارند.

۴-۳-۲- نرخ خطای انتخاب مقدار از قید نادرست

یکی از معیارهای اصلی این پژوهش نرخ WQSV است. این خطا زمانی رخ می‌دهد که مدل به جای مقدار مرتبط با قید درخواست شده، یک مقدار معتبر و صریح از همان شواهد را انتخاب کند که متعلق به قید رقیب است.

$$WQSVRate = (N_{(WQSV)})/N$$

در این تعریف، مخرج کل پرسش‌ها است و نه فقط پرسش‌هایی که مدل در آن‌ها اشتباه کرده است.

برای بررسی سهم WQSV از کل خطاهای مدل، معیار مکمل زیر نیز استفاده می‌شود:

^۱ Prompt

^۲ Accuracy

$$WQSVShareofErrors = (N_{(WQSV)}) / (N - N_{(Correct)})$$

این معیار نشان می‌دهد چه سهمی از پاسخ‌های نادرست مدل ناشی از انتخاب مقدار متعلق به یک قید رقیب بوده است.

۴-۳-۳- دقت زوجی

هر پیکربندی فین‌اسکوپ شامل دو پرسش دوقلوی متقابل است. بنابراین علاوه بر دقت در سطح پرسش، عملکرد مدل در سطح پیکربندی نیز ارزیابی می‌شود. یک پیکربندی تنها زمانی صحیح در نظر گرفته می‌شود که مدل هر دو پرسش A و B را به درستی پاسخ دهد:

$$PairCorrect = 1 \Leftrightarrow A_{Correct} \wedge B_{Correct}$$

در نتیجه دقت زوجی^۱ به صورت زیر محاسبه می‌شود:

$$PairAccuracy = \frac{N_{BothCorrect}}{N_{Configurations}}$$

این معیار نسبت به دقت معمولی سخت‌گیرانه‌تر است؛ زیرا مدلی که تنها یکی از دو جهت اتصال قید به مقدار را درست پاسخ دهد، در سطح پیکربندی موفق محسوب نمی‌شود.

جدول ۴-۳. معیارهای اصلی مورد استفاده در ارزیابی

معیار	تعریف
دقت	نسبت پاسخ‌های صحیح به کل پرسش‌ها
نرخ WQSV	نسبت خطاهای انتخاب مقدار از قید نادرست به کل پرسش‌ها
سهم WQSV از خطاها	نسبت WQSV به کل پاسخ‌های نادرست
دقت زوجی	نسبت پیکربندی‌هایی که هر دو پرسش آن‌ها صحیح پاسخ داده شده‌اند

^۱ Pair Accuracy

۴-۴- نتایج کلی مدل‌ها

جدول ۴-۴ نتایج تجربی سه مدل را در چهار بخش مورد بررسی نشان می‌دهد. همان‌طور که پیش‌تر بیان شد، این نتایج متعلق به اجراهای تجربی مرحله‌ای پروژه هستند و نباید به‌عنوان رتبه‌بندی نهایی همه مدل‌های فین‌اسکوپ تفسیر شوند.

جدول ۴-۴. دقت و تعداد خطاهای WQSV سه مدل منتخب در بخش‌های مختلف فین‌اسکوپ

بخش	گما-۲-۲بی- آی تی	جی پی تی-اواس اس- ۱۲۰بی	جی پی تی-۵،۶- سول
V1	۳۷ / ۸۱،۲۵٪	۲۹ / ۸۹،۳۸٪	۱۴ / ۹۵،۶۳٪
V2	۳۸ / ۷۱،۵۶٪	۲ / ۹۶،۵۶٪	۰ / ۱۰۰،۰۰٪
V3	۶۸ / ۸۵،۴۲٪	۱۴ / ۹۷،۰۸٪	۶ / ۹۸،۷۵٪
داده‌های واقعی	۲۲ / ۵۹،۹۳٪	۰ / ۹۰،۴۴٪	۰ / ۹۱،۵۴٪

در هر خانه جدول، مقدار اول دقت و مقدار دوم تعداد موارد WQSV را نشان می‌دهد. نتایج نشان می‌دهد که در تمام بخش‌های مورد بررسی، جی پی تی-۵،۶ سول بالاترین دقت مشاهده‌شده را در میان سه مدل داشته است. پس از آن، جی پی تی-اواس اس-۱۲۰بی قرار دارد و گما-۲-۲بی-آی تی در هر چهار بخش دقت پایین‌تری نشان داده است.

باین‌حال، تفاوت عملکرد میان V1، V2 و V3 روند یکنواختی ندارد. برای مثال، دقت گما از ۸۱،۲۵٪ در V1 به ۷۱،۵۶٪ در V2 کاهش یافته، اما در V3 به ۸۵،۴۲٪ افزایش یافته است. در مقابل، جی پی تی-اواس اس در V2 و V3 عملکرد بسیار بالاتری نسبت به V1 نشان داده است.

این رفتار نشان می‌دهد که سه نسخه مصنوعی را نباید به‌عنوان سه «سطح دشواری» پیوسته در نظر گرفت. هر نسخه با اهداف طراحی و ترکیب متفاوتی ساخته شده است و تفاوت دقت میان نسخه‌ها تنها یک مشاهده توصیفی از رفتار مدل روی مجموعه‌های متفاوت است.

یکی از نتایج قابل توجه مربوط به جی پی تی-۵،۶ سول در V2 است. این مدل هر ۶۴۰ پرسش را به‌درستی پاسخ داده و دقت ۱۰۰٪ به دست آورده است؛ در نتیجه در این اجرا هیچ نمونه WQSV برای این مدل مشاهده نشده است. باین‌حال، در V3 مجدداً ۶ مورد WQSV برای همین مدل مشاهده می‌شود. بنابراین نبود WQSV در یک مجموعه مشخص را نمی‌توان به‌عنوان ناتوانی مطلق مدل در تولید این نوع خطا تفسیر کرد.

۴-۵- تحلیل عملکرد در نسخه‌های مصنوعی

برای ایجاد تصویری کلی از عملکرد مدل‌ها روی داده‌های مصنوعی، تعداد پاسخ‌های صحیح در V1، V2 و V3 با یکدیگر جمع شده‌اند. این محاسبه تنها یک تجمیع توصیفی است و به معنی اجرای یک آزمایش واحد روی نسخه نهایی مجموعه داده نیست.

جدول ۴-۵. تجمیع توصیفی نتایج سه بخش مصنوعی

مدل	تعداد پرسش	تعداد صحیح	دقت	تعداد WQSV	نرخ WQSV
گما-۲-۲ بی-آی تی	۱,۴۴۰	۱,۱۲۸	۷۸,۳۳٪	۱۴۳	۹,۹۳٪
جی پی تی-اواس اس-۱۲۰ بی	۱,۴۴۰	۱,۳۷۰	۹۵,۱۴٪	۴۵	۳,۱۳٪
جی پی تی-۵,۶ سول	۱,۴۴۰	۱,۴۲۰	۹۸,۶۱٪	۲۰	۱,۳۹٪

بر اساس این تجمیع توصیفی، اختلاف عملکرد میان سه مدل قابل توجه است. گما در مجموع ۳۱۲ پاسخ نادرست داشته است، در حالی که این مقدار برای جی پی تی-اواس اس ۷۰ و برای جی پی تی-۵,۶ سول تنها ۲۰ مورد بوده است.

در عین حال، کاهش تعداد کل خطاها الزاماً به معنای حذف خطای اتصال قید به مقدار نیست. حتی جی پی تی-۵,۶ سول که در مجموع داده‌های مصنوعی دقت ۹۸,۶۱٪ داشته، ۲۰ مورد WQSV تولید کرده است. این مشاهده نشان می‌دهد که دستیابی به دقت کلی بالا، به تنهایی تضمین کننده حذف خطاهای اتصال قید به مقدار نیست.

۴-۶- تحلیل پرسش‌های دوقلو و خطای WQSV

۴-۶-۱- تحلیل در سطح پیکربندی

از آنجا که هر پیکربندی فین‌اسکوپ دارای دو پرسش متقابل است، بررسی دقت زوجی می‌تواند ضعف‌هایی را آشکار کند که در دقت سؤال‌محور کمتر قابل مشاهده هستند.

جدول ۴-۶. دقت زوجی سه مدل در بخش‌های مختلف

بخش	گما-۲-بی- آی تی	جی پی تی-اواس اس- ۱۲۰ بی	جی پی تی-۵۶- سول
V1	۶۹,۳۸٪	۸۰,۶۳٪	۹۱,۲۵٪
V2	۶۵,۹۴٪	۹۵,۶۳٪	۱۰۰,۰۰٪
V3	۷۲,۰۸٪	۹۴,۱۷٪	۹۷,۹۲٪
داده‌های واقعی	۴۱,۱۸٪	۸۸,۹۷٪	۹۱,۱۸٪

مقایسه جدول‌های ۴-۴ و ۴-۶ نشان می‌دهد که دقت زوجی همواره برابر یا کمتر از دقت سؤال‌محور است. دلیل این امر آن است که برای موفقیت در سطح پیکربندی، مدل باید هر دو جهت اتصال را به‌درستی تشخیص دهد.

این اختلاف برای گما به‌ویژه در داده‌های واقعی قابل توجه است. دقت سؤال‌محور این مدل ۵۹,۹۳٪ است، اما دقت زوجی آن به ۴۱,۱۸٪ کاهش می‌یابد. این موضوع نشان می‌دهد که بخشی از موفقیت‌های سؤال‌محور مدل در دو جهت یک پیکربندی پایدار نیست.

در V2، جی پی تی-۵۶ سول هر ۳۲۰ پیکربندی را به‌طور کامل حل کرده است. جی پی تی-اواس اس نیز در ۳۰۶ پیکربندی از ۳۲۰ پیکربندی هر دو سؤال را صحیح پاسخ داده است، در حالی که این مقدار برای گما ۲۱۱ پیکربندی بوده است.

۴-۶-۲- سهم WQSV از خطاهای مدل

صرف شمارش WQSV برای مقایسه مدل‌ها کافی نیست؛ زیرا مدل‌هایی با تعداد خطای بیشتر به‌طور طبیعی فرصت بیشتری برای تولید WQSV دارند. بنابراین سهم WQSV از کل پاسخ‌های نادرست نیز محاسبه شده است.

جدول ۴-۷. سهم WQSV از خطاهای مدل‌ها در سه بخش مصنوعی

مدل	کل پاسخ‌های نادرست	تعداد WQSV	سهم WQSV از خطاها
گما-۲-۲ بی-آی تی	۳۱۲	۱۴۳	۴۵٫۸۳٪
جی پی تی-اواس اس- ۱۲۰ بی	۷۰	۴۵	۶۴٫۲۹٪
جی پی تی-۵٫۶ سول	۲۰	۲۰	۱۰۰٫۰۰٪

جدول ۴-۷ یک نکته مهم را نشان می‌دهد. در حالی که جی پی تی-۵٫۶ سول تعداد خطای بسیار کمتری دارد، تمام ۲۰ خطای مشاهده شده آن در سه بخش مصنوعی از نوع WQSV بوده‌اند. در جی پی تی-اواس اس نیز ۴۵ مورد از ۷۰ خطا در این دسته قرار گرفته‌اند. این نتیجه نباید به این صورت تفسیر شود که مدل‌های توانمندتر ذاتاً بیشتر دچار WQSV می‌شوند. تفسیر مناسب‌تر این است که با کاهش سایر انواع خطا، سهم نسبی خطاهای باقی‌مانده مرتبط با انتخاب مقدار رقیب می‌تواند افزایش یابد. در مقابل، گما علاوه بر WQSV انواع دیگری از خطا را نیز به تعداد زیاد تولید کرده است. برای مثال، در V2 تعداد قابل توجهی خطای مرتبط با علامت عدد مشاهده شده بود. از این رو، همه خطاهای جَمّا را نمی‌توان به مسئله اتصال قید به مقدار نسبت داد.

۴-۷- مقایسه داده‌های مصنوعی و داده‌های واقعی

برای بررسی رفتار مدل‌ها خارج از نمونه‌های کاملاً مصنوعی، یک مجموعه مبتنی بر اسناد مالی واقعی نیز در پروژه در نظر گرفته شده است. این بخش شامل ۱۳۶ پیکربندی و ۲۷۲ پرسش است. نتایج موجود این بخش مربوط به اجرای تجربی مرحله‌ای پیش از ارزیابی جامع نهایی است؛ بنابراین مقایسه آن با داده‌های مصنوعی صرفاً ماهیت توصیفی دارد.

جدول ۴-۸. مقایسه توصیفی دقت مدل‌ها در داده‌های مصنوعی و واقعی

مدل	دقت در داده‌های مصنوعی	دقت در داده‌های واقعی	اختلاف
گما-۲-۲بی-آی تی	۷۸,۳۳٪	۵۹,۹۳٪	۱۸,۴۰ - واحد درصد
جی پی تی - اواس اس -۱۲۰ بی	۹۵,۱۴٪	۹۰,۴۴٪	۴,۷۰ - واحد درصد
جی پی تی -۵,۶ سول	۹۸,۶۱٪	۹۱,۵۴٪	۷,۰۷ - واحد درصد

در هر سه مدل، دقت مشاهده شده در مجموعه واقعی پایین تر از تجمیع سه بخش مصنوعی است. بیشترین کاهش مربوط به گما با حدود ۱۸,۴۰ واحد درصد است. این اختلاف برای جی پی تی -اواس اس حدود ۴,۷۰ و برای جی پی تی -۵,۶ سول حدود ۷,۰۷ واحد درصد بوده است. بالاین حال، نمی توان این اختلاف را صرفاً به «واقعی بودن» داده‌ها نسبت داد؛ زیرا دو مجموعه از نظر نحوه ساخت، توزیع نمونه‌ها و ترکیب پدیده‌های زبانی متفاوت هستند. بنابراین این مقایسه نباید به صورت یک رابطه علی تفسیر شود.

جدول ۴-۹. مقایسه توصیفی نرخ WQSV در داده‌های مصنوعی و واقعی

مدل	نرخ WQSV در داده‌های مصنوعی	نرخ WQSV در داده‌های واقعی
گما-۲-۲بی-آی تی	۹,۹۳٪	۸,۰۹٪
جی پی تی -اواس اس - ۱۲۰ بی	۳,۱۳٪	۰,۰۰٪
جی پی تی -۵,۶ سول	۱,۳۹٪	۰,۰۰٪

در اجرای موجود روی داده‌های واقعی، برای جی پی تی -اواس اس و جی پی تی -۵,۶ سول نمونه WQSV مشاهده نشده است. این نتیجه صرفاً بیانگر صفر مورد مشاهده شده در این نمونه و این اجرای خاص است و نمی توان از آن نتیجه گرفت که این مدل‌ها در اسناد مالی واقعی قادر به تولید چنین خطایی نیستند. همچنین مجموعه واقعی فین اسکوپ برای تخمین شیوع WQSV در کل اسناد مالی طراحی نشده است. بنابراین مقادیر جدول ۴-۹ نباید به عنوان برآوردی از فراوانی این پدیده در کاربردهای واقعی مالی تفسیر شوند.

۴-۸- تحلیل آماری و خطاها

۴-۸-۱- مقایسه زوجی مدل‌ها

برای مقایسه عملکرد مدل‌ها روی پرسش‌های یکسان از آزمون دقیق مک‌نمار^۱ استفاده شده است. از آنجا که چند مقایسه همزمان انجام شده، مقادیر احتمال با روش هولم^۲ اصلاح شده‌اند.

جدول ۴-۱۰. نتایج آزمون مک‌نمار با اصلاح هولم در V1

مقایسه	مقدار احتمال اصلاح شده
گما در برابر جی پی تی-اواس اس	۰,۰۰۱۶۴
گما در برابر جی پی تی-۵,۶ سول	$۲,۳۰ \times ۱۰^{-۹}$
جی پی تی-اواس اس در برابر جی پی تی-۵,۶ سول	۰,۰۰۱۶۴

هر سه اختلاف در V1 از نظر آماری معنادار بوده‌اند.

جدول ۴-۱۱. نتایج آزمون مک‌نمار با اصلاح هولم در V2

مقایسه	مقدار احتمال اصلاح شده
گما در برابر جی پی تی-اواس اس	$۱,۱۲ \times ۱۰^{-۴۶}$
گما در برابر جی پی تی-۵,۶ سول	$۹,۷۹ \times ۱۰^{-۵۵}$
جی پی تی-اواس اس در برابر جی پی تی-۵,۶ سول	$۴,۷۷ \times ۱۰^{-۷}$

در V2 نیز اختلاف هر سه زوج مدل معنادار است.

^۱ McNemar Test

^۲ Holm Correction

جدول ۴-۱۲. نتایج آزمون مک‌نمار با اصلاح هولم در V3

مقدار احتمال اصلاح شده	مقایسه
$10^{-12} \times 1,64$	گما در برابر جی پی تی - اواس اس
$10^{-16} \times 2,91$	گما در برابر جی پی تی - ۵,۶ سول
۰,۰۵۷۴	جی پی تی - اواس اس در برابر جی پی تی - ۵,۶ سول

در V3، اختلاف گما با هر دو مدل دیگر همچنان معنادار است. با این حال، اختلاف میان جی پی تی - اواس اس و جی پی تی - ۵,۶ سول پس از اصلاح هولم در سطح متعارف ۰,۰۵ معنادار نیست. این نتیجه اهمیت استفاده از آزمون‌های زوجی را نشان می‌دهد؛ زیرا اختلاف عددی دقت الزاماً به معنای اختلاف آماری قابل اتکا نیست.

۴-۸-۲- تحلیل خطاهای مشترک

یکی از مشاهدات قابل توجه در V3 مربوط به مواردی است که بیش از یک مدل در یک سؤال مشخص شکست خورده‌اند. در این نسخه، ۱۲ سؤال وجود داشته است که حداقل دو مدل آن‌ها را نادرست پاسخ داده‌اند و هر ۱۲ مورد از نوع WQSV بوده‌اند.

همچنین یک سؤال وجود داشته است که هر سه مدل در آن پاسخ نادرست از نوع WQSV تولید کرده‌اند.

این نتیجه نشان می‌دهد برخی نمونه‌ها می‌توانند برای چند مدل به‌طور همزمان چالش‌برانگیز باشند. با این حال، از این مشاهده نمی‌توان نتیجه گرفت که این نمونه‌ها به‌طور عمومی برای همه مدل‌های زبانی دشوار هستند، زیرا تحلیل حاضر تنها شامل سه مدل است.

۴-۸-۳- محدودیت‌های نتایج تجربی

نتایج این فصل با چند محدودیت همراه هستند که باید در تفسیر آن‌ها در نظر گرفته شوند. نخست، ارزیابی عددی این پایان‌نامه تنها بر سه مدل منتخب متمرکز است، در حالی که زیرساخت فین‌اسکوپ برای پنل بزرگ‌تری از مدل‌ها طراحی شده است. بنابراین رتبه‌بندی مشاهده‌شده میان این سه مدل نباید به کل مدل‌های موجود تعمیم داده شود.

دوم، اجراهای V1، V2، و V3 و بخش واقعی در مراحل مختلف توسعه پروژه انجام شده‌اند. از این‌رو، جمعیت نتایج آن‌ها در این فصل صرفاً برای ارائه یک تصویر توصیفی از رفتار سه مدل استفاده شده است. سوم، نسخه‌های V1، V2 و V3 دارای طراحی و ترکیب متفاوت هستند و به‌عنوان سطوح متوالی دشواری تعریف نشده‌اند. در نتیجه، افزایش یا کاهش دقت میان این نسخه‌ها نباید به‌عنوان تغییر مستقیم در سطح دشواری تفسیر شود.

چهارم، مجموعه داده‌های واقعی برای نشان دادن امکان وقوع مسئله اتصال قید به مقدار در نمونه‌های مبتنی بر اسناد واقعی استفاده شده و هدف آن برآورد شیوع این خطا در کل حوزه مالی نیست. پنجم، WQSV یک برچسب رفتاری قابل مشاهده است. مشاهده این خطا نشان می‌دهد مدل یک مقدار صریح متعلق به قید رقیب را انتخاب کرده است؛ اما این موضوع به‌تنهایی اثبات نمی‌کند که یک سازوکار عصبی یا شناختی مستقل درون مدل مسئول این خطا بوده است.

۴-۹- جمع‌بندی

در این فصل، نتایج تجربی سه مدل گما-۲-۲ بی-آی تی، جی پی تی-اواس اس-۱۲۰ بی و جی پی تی-۵۶ سول در بخش‌های مختلف فین‌اسکوپ بررسی شد. نتایج نشان داد که در مجموعه آزمایش‌های موجود، جی پی تی-۵۶ سول بالاترین دقت مشاهده‌شده را در میان سه مدل داشته و جی پی تی-اواس اس نیز در اغلب بخش‌ها عملکردی نزدیک به آن ارائه کرده است. در مقابل، جما در هر چهار بخش دقت پایین‌تری نشان داده است.

تحلیل نسخه‌های مصنوعی نشان داد که تغییر عملکرد از V1 به V2 و V3 روند یکنواختی ندارد. این مشاهده با نقش متفاوت این نسخه‌ها در طراحی فین‌اسکوپ سازگار است و تأکید می‌کند که نباید آن‌ها را به‌عنوان سطوح متوالی دشواری در نظر گرفت.

بررسی خطای WQSV نیز نشان داد که این پدیده محدود به مدل‌های ضعیف‌تر نیست. در مجموع سه بخش مصنوعی، گما ۱۴۳، جی پی تی-اواس اس ۴۵ و جی پی تی-۵۶ سول ۲۰ خطای WQSV تولید کرده‌اند. در مدل جی پی تی-۵۶ سول تمام خطاهای مشاهده‌شده در داده‌های مصنوعی از این نوع بوده‌اند. با این حال، V2 نمونه‌ای مهم از تغییرپذیری این پدیده است؛ زیرا این مدل در آن نسخه به دقت ۱۰۰٪ رسیده و هیچ WQSV مشاهده نشده است، در حالی که در V1 و V3 این خطا دوباره دیده می‌شود.

تحلیل پرسش‌های دوقلو نیز نشان داد که دقت زوجی اطلاعات تکمیلی مهمی نسبت به دقت سؤال‌محور فراهم می‌کند. مدلی ممکن است در تعداد زیادی از پرسش‌ها پاسخ صحیح بدهد، اما در جابجایی قید هدف میان دو پرسش یک پیکربندی، رفتار کاملاً پایدار نداشته باشد.

در داده‌های واقعی، هر سه مدل دقت پایین‌تری نسبت به تجمیع توصیفی داده‌های مصنوعی نشان دادند. با این حال، به دلیل تفاوت ساختاری میان این مجموعه‌ها، این اختلاف صرفاً به صورت توصیفی گزارش شد و از آن نتیجه‌گیری یا برآوردی درباره شیوع خطا در اسناد مالی واقعی استخراج نشد.

در مجموع، نتایج تجربی این فصل نشان می‌دهند که ارزیابی صرف بر مبنای دقت کلی برای شناخت رفتار مدل‌ها کافی نیست و بررسی رابطه میان قید درخواست‌شده، مقدار انتخاب‌شده و رفتار مدل روی پرسش‌های متقابل می‌تواند اطلاعات تشخیصی بیشتری درباره نوع خطا فراهم کند. ارزیابی تکمیلی مدل‌های بیشتر و اجرای جامع‌تر نسخه‌های فین‌اسکوپ در مراحل بعدی پروژه می‌تواند تصویر کامل‌تری از پایداری این یافته‌ها ارائه دهد.

فصل پنجم

نتیجه‌گیری و پیشنهادات

۵-۱- مقدمه

این پژوهش با هدف بررسی دقیق‌تر قابلیت مدل‌های هوش مصنوعی در تحلیل و استدلال روی داده‌های مالی انجام شد. مسئله اصلی پژوهش از این مشاهده آغاز شد که در بسیاری از وظایف پرسش‌وپاسخ مالی، یک مدل ممکن است به مقداری پاسخ دهد که واقعاً در متن یا جدول منبع وجود دارد، اما آن مقدار به قید یا زمینه دیگری مربوط باشد. در چنین شرایطی، پاسخ مدل صرفاً یک مقدار ساختگی یا بازیابی‌نشده نیست، بلکه خطا در اتصال صحیح قید درخواست‌شده به مقدار متناظر رخ داده است.

بر این اساس، در این پژوهش مفهوم **اتصال قید به مقدار** به‌عنوان چارچوب اصلی تحلیل مسئله در نظر گرفته شد و خطای **انتخاب مقدار منبع از قید نادرست** به‌عنوان یک برجسته عملیاتی برای شناسایی این نوع خطا تعریف شد. برای مطالعه نظام‌مند این مسئله، مجموعه ارزیابی **فین‌اسکوپ** طراحی و توسعه داده شد تا بتوان در یک محیط کنترل‌شده، رفتار مدل‌ها را در انتخاب میان مقادیر رقیب و از نظر رابطه میان قید و مقدار بررسی کرد.

در فصل‌های پیشین، ابتدا مبانی نظری و پژوهش‌های مرتبط در زمینه هوش مصنوعی مالی، پرسش‌وپاسخ مالی، استدلال عددی، بازیابی شواهد و خطاهای مدل‌های زبانی بررسی شد. سپس ساختار فین‌اسکوپ، خانواده‌های قیدی، فرایند تولید و اعتبارسنجی داده‌ها، سازوکار امتیازدهی و زیرساخت ارزیابی معرفی گردید. در ادامه نیز نتایج تجربی سه مدل منتخب در بخش‌های مختلف مجموعه‌داده تحلیل شد. در این فصل، مهم‌ترین دستاوردها و یافته‌های پژوهش جمع‌بندی شده و محدودیت‌ها و مسیرهای پیشنهادی برای ادامه کار ارائه می‌شوند.

۵-۲- جمع‌بندی پژوهش

نقطه آغاز این پروژه، مطالعه گسترده پژوهش‌های هوش مصنوعی در حوزه مالی بود. در مرحله مرور نظام‌مند ادبیات، پژوهش‌های مرتبط با داده‌های عددی، متنی، تصویری و چندوجهی در حوزه مالی بررسی شدند. این مرور نشان داد که بخش قابل توجهی از پژوهش‌ها بر پیش‌بینی قیمت، تحلیل روند بازار یا ترکیب منابع داده متمرکز هستند، در حالی که موضوع قابلیت اعتماد مدل در انتخاب و اتصال صحیح اطلاعات موجود در یک منبع مالی، به‌ویژه در شرایط وجود چند مقدار رقیب، نیازمند بررسی دقیق‌تری است.

در ادامه، تمرکز پژوهش از مسئله عمومی تحلیل بازارهای مالی به مسئله محدودتر و قابل‌کنترل‌تر درک و استدلال در پرسش‌وپاسخ مالی منتقل شد. بررسی نمونه‌های خطای مدل‌ها نشان داد که بخشی از پاسخ‌های نادرست را نمی‌توان صرفاً در دسته‌هایی مانند توهم، شکست بازیابی یا اشتباه محاسباتی قرار داد. در برخی نمونه‌ها، مدل مقدار عددی صحیحی را از منبع استخراج می‌کرد، اما این مقدار مربوط به قید دیگری بود. همین الگوی رفتاری، مبنای صورت‌بندی مسئله اتصال قید به مقدار و تعریف WQSV شد.

برای بررسی این پدیده، مجموعه فین‌اسکوپ طراحی شد. ساختار اصلی این مجموعه بر پیکربندی‌هایی استوار است که در هر کدام حداقل دو مقدار منبع وجود دارند که از نظر موجودیت، معیار، دوره یا واحد مشابه‌اند، اما تحت قیود متفاوت تعریف شده‌اند. برای هر پیکربندی دو پرسش متقابل ساخته می‌شود تا مدل در هر بار پاسخ‌گویی مجبور باشد قید هدف را به مقدار صحیح متصل کند.

نسخه نهایی فریز شده فین‌اسکوپ شامل ۸۵۶ پیکربندی و ۱۰۷۱۲ پرسش است. از این تعداد، ۱۰۴۴۰ پرسش متعلق به سه بخش مصنوعی V1، V2 و V3 و ۲۷۲ پرسش مربوط به بخش مبتنی بر داده‌های واقعی است. همچنین چهار خانواده قیدی اصلی در نسخه نهایی مجموعه داده در نظر گرفته شده‌اند: مبنای ارائه، مبنای ارزی، موقعیت راهنمایی و دامنه گزارش‌دهی.

یکی دیگر از بخش‌های مهم پروژه، طراحی فرایند اعتبارسنجی و کنترل کیفیت بود. نمونه‌ها از نظر امکان بازیابی پاسخ از شواهد ارائه‌شده، عدم نیاز به دانش خارجی، عدم وابستگی به محاسبه پنهان و صحت ساختار پرسش‌های دوقلو بررسی شدند. علاوه بر این، ممیزی‌های مختلفی برای کاهش میانبرهای سطحی، هم‌پوشانی بیش از حد و نشت اطلاعات طراحی شد.

در بخش ارزیابی نیز یک نرمال‌ساز و امتیازدهنده مستقل طراحی شد تا پاسخ‌های مدل‌ها به‌صورت یکنواخت پردازش شوند. خروجی هر پرسش در یکی از چهار دسته پاسخ صحیح، WQSV، سایر پاسخ‌های نادرست و پاسخ نامعتبر قرار می‌گیرد. این تفکیک امکان تحلیل دقیق‌تر رفتار مدل را فراهم می‌کند و مانع از آن می‌شود که همه پاسخ‌های نادرست در یک دسته کلی قرار گیرند.

در نهایت، نتایج تجربی سه مدل گما-۲-۲ بی-آی تی، جی پی تی-اواس اس-۱۲۰ بی و جی پی تی-۵۰۶ سول

در بخش‌های مختلف فین‌اسکوپ بررسی شدند. هدف اصلی این مرحله نه ایجاد یک رتبه‌بندی نهایی جامع، بلکه بررسی این موضوع بود که آیا خطای WQSV در مدل‌هایی با توانایی‌های متفاوت قابل مشاهده است و آیا تحلیل در سطح پرسش‌های دوقلو اطلاعات بیشتری نسبت به دقت کلی ارائه می‌دهد.

۵-۳- یافته‌های اصلی پژوهش

یکی از مهم‌ترین یافته‌های این پژوهش آن است که دقت کلی به‌تنهایی برای ارزیابی رفتار مدل در پرسش‌وپاسخ مالی کافی نیست. یک مدل ممکن است دقت بالایی داشته باشد، اما در تعداد محدودی از نمونه‌ها مقدار صریح موجود در منبع را به قید نادرست متصل کند. چنین خطایی در ارزیابی‌های صرفاً مبتنی بر صحیح یا غلط بودن پاسخ قابل مشاهده است، اما ماهیت آن مشخص نمی‌شود.

نتایج تجربی نشان دادند که WQSV در چندین مدل و در چند بخش مختلف مجموعه داده مشاهده می‌شود. در سه بخش مصنوعی، تعداد WQSV برای گما برابر ۱۴۳، برای جی‌پی‌تی-اواس اس برابر ۴۵ و برای جی‌پی‌تی-۵۰۶ سول برابر ۲۰ مورد بود. این نتایج نشان می‌دهد که خطای اتصال قید به مقدار تنها به مدل‌های ضعیف‌تر محدود نیست.

بالین حال، رفتار WQSV در نسخه‌های مختلف ثابت نبود. برای نمونه، جی‌پی‌تی-۵۰۶ سول در V2 به دقت ۱۰۰٪ رسید و هیچ نمونه WQSV برای آن مشاهده نشد، در حالی که در V1 و V3 این خطا دوباره ظاهر شد. بنابراین، نبود WQSV در یک مجموعه یا اجرای خاص نباید به‌عنوان حذف کامل این نوع خطا از رفتار مدل تفسیر شود.

یافته مهم دیگر مربوط به ارزیابی در سطح پرسش‌های دوقلو است. مقایسه دقت سؤال‌محور با دقت زوجی نشان داد که برخی مدل‌ها ممکن است یک جهت از اتصال قید به مقدار را درست پاسخ دهند، اما در جهت متقابل همان پیکربندی موفق نباشند. بنابراین ساختار دوقلو امکان بررسی سازگاری رفتاری مدل را فراهم می‌کند.

همچنین تفاوت عملکرد میان V1، V2 و V3 روند یکنواختی نداشت. برای مثال، عملکرد گما در V2 نسبت به V1 کاهش پیدا کرد، اما در V3 افزایش یافت. این موضوع تأیید می‌کند که این سه نسخه نباید به‌عنوان سطوح متوالی و خطی دشواری تفسیر شوند. هر نسخه با هدف طراحی و ترکیب متفاوتی ساخته شده و اختلاف عملکرد میان آن‌ها صرفاً باید به‌صورت توصیفی تحلیل شود.

در بخش داده‌های واقعی نیز دقت مشاهده‌شده هر سه مدل نسبت به تجمیع داده‌های مصنوعی پایین‌تر بود. بالین حال، به دلیل تفاوت میان نحوه ساخت و توزیع دو مجموعه، این اختلاف نباید به‌عنوان اثر علی «واقعی بودن» داده یا برآوردی از دشواری کلی اسناد مالی تفسیر شود.

در مجموع، نتایج نشان می‌دهند که بررسی رابطه میان قید درخواست‌شده و مقدار انتخاب‌شده، نسبت به گزارش صرف دقت کلی، اطلاعات تشخیصی بیشتری درباره رفتار مدل ارائه می‌کند.

۵-۴- محدودیت‌های پژوهش

با وجود تلاش برای طراحی کنترل‌شده فین‌اسکوپ و اعتبارسنجی دقیق آن، این پژوهش دارای محدودیت‌هایی است که باید در تفسیر نتایج مورد توجه قرار گیرند.

نخست، نتایج تجربی گزارش‌شده در این پایان‌نامه بر سه مدل منتخب متمرکز هستند. زیرساخت ارزیابی پروژه برای مدل‌های بیشتری طراحی شده است، اما نتایج آن‌ها در تحلیل اصلی این پایان‌نامه وارد نشده‌اند. بنابراین نتایج به‌دست‌آمده نباید به‌عنوان رتبه‌بندی جامع مدل‌های زبانی موجود تلقی شوند.

دوم، اجراهای V1، V2، و V3 و بخش داده‌های واقعی در مراحل مختلف توسعه پروژه انجام شده‌اند. هرچند این نتایج واقعی و ثبت‌شده هستند، اما همه آن‌ها از یک اجرای واحد و یکپارچه روی نسخه نهایی مجموعه داده حاصل نشده‌اند. در نتیجه، مقایسه میان نسخه‌ها باید با احتیاط و عمدتاً به‌صورت توصیفی انجام شود.

سوم، بخش داده‌های واقعی فین‌اسکوپ با هدف بررسی امکان مشاهده مسئله اتصال قید به مقدار در نمونه‌های مبتنی بر اسناد واقعی ساخته شده است و برای برآورد آماری شیوع این خطا در کل اسناد مالی طراحی نشده است. بنابراین نرخ‌های مشاهده‌شده WQSV در این بخش قابل تعمیم به کل حوزه مالی نیستند.

چهارم، فین‌اسکوپ عمدتاً بر محیط بسته و شواهد ارائه‌شده متمرکز است. در چنین شرایطی، مدل نیازی به جست‌وجوی خارجی یا بازایی اسناد ندارد. بنابراین نتایج حاضر درباره خطای اتصال قید به مقدار در شرایطی هستند که مسئله بازایی اطلاعات تا حد زیادی کنترل شده است.

پنجم، WQSV یک تعریف عملیاتی رفتاری است. مشاهده این خطا نشان می‌دهد که خروجی مدل با یک مقدار صریح متعلق به قید رقیب مطابقت دارد، اما این مشاهده به‌تنهایی توضیح نمی‌دهد که چه فرایند داخلی یا بازنمایی عصبی درون مدل باعث این پاسخ شده است.

ششم، خانواده‌های قیدی تعریف‌شده در فین‌اسکوپ یک رده‌بندی عملیاتی برای این پروژه هستند و نباید به‌عنوان یک رده‌بندی جامع و نهایی برای تمام انواع قیود موجود در اسناد مالی در نظر گرفته شوند.

۵-۵- پیشنهادها برای کارهای آینده

یکی از مسیرهای اصلی ادامه این پژوهش، اجرای کامل‌تر زیرساخت ارزیابی روی مجموعه گسترده‌تری

از مدل‌ها است. مقایسه مدل‌هایی از خانواده‌ها و مقیاس‌های مختلف می‌تواند مشخص کند که آیا الگوهای مشاهده‌شده در سه مدل فعلی در مجموعه بزرگ‌تری نیز تکرار می‌شوند یا خیر.

مسیر دوم، اجرای مجدد همه مدل‌ها روی نسخه نهایی فین‌اسکوپ با یک پروتکل و امتیازدهنده کاملاً یکسان است. چنین اجرایی امکان مقایسه دقیق‌تر بین مدل‌ها، خانواده‌های قیدی و بخش‌های مختلف مجموعه داده را فراهم خواهد کرد.

گسترش بخش داده‌های واقعی نیز از اهمیت بالایی برخوردار است. افزایش تعداد اسناد، شرکت‌ها، دوره‌های زمانی و قالب‌های گزارش‌دهی می‌تواند به بررسی پایداری نتایج در شرایط متنوع‌تر کمک کند. با این حال، چنین توسعه‌ای باید همراه با کنترل دقیق منبع، مجوز استفاده و اعتبارسنجی انسانی انجام شود. مسیر دیگر، گسترش خانواده‌های قیدی است. در این پژوهش چهار خانواده اصلی مورد استفاده قرار گرفتند، اما اسناد مالی می‌توانند شامل قیود دیگری مانند نوع سناریو، بازه زمانی خاص، مبنای محاسباتی، منطقه جغرافیایی یا سطح سازمانی باشند.

همچنین می‌توان از فین‌اسکوپ به عنوان بستری برای بررسی روش‌های کاهش WQSV استفاده کرد. برای مثال، روش‌های آموزش نظارت‌شده، دستوردهی ساختاریافته، بازیابی مبتنی بر قید، بازرتبه‌بندی شواهد یا روش‌های خودبازبینی می‌توانند از نظر تأثیر بر کاهش این خطا مقایسه شوند.

یک مسیر پژوهشی مهم‌تر، بررسی بازنمایی‌های داخلی مدل‌ها است. ابزارهایی مانند پروب‌گذاری خطی^۱، مداخله در فعال‌سازی‌ها^۲ یا تحلیل بازنمایی می‌توانند برای بررسی این موضوع استفاده شوند که آیا مدل پیش از تولید پاسخ، قید و مقدار صحیح را در بازنمایی‌های داخلی خود تفکیک کرده است یا خیر.

در نهایت، می‌توان فین‌اسکوپ را از یک مجموعه صرفاً تشخیصی به یک چارچوب ارزیابی برای سامانه‌های مالی تعاملی گسترش داد؛ به گونه‌ای که علاوه بر پاسخ نهایی، شواهد انتخاب‌شده، قید مورد استفاده و میزان اطمینان مدل نیز بررسی شوند.

۵-۶- جمع‌بندی

در این فصل، دستاوردها و نتایج اصلی پژوهش جمع‌بندی شد. مسئله اصلی این پایان‌نامه، بررسی خطاهایی بود که در آن مدل به یک مقدار معتبر و موجود در منبع پاسخ می‌دهد، اما آن مقدار را از قید نادرست انتخاب می‌کند. برای بررسی نظام‌مند این مسئله، مفهوم اتصال قید به مقدار و خطای WQSV در چارچوب فین‌اسکوپ مورد استفاده قرار گرفت.

^۱ Linear Probing

^۲ Activation Intervention

فین اسکوپ با استفاده از پرسش‌های دوقلو، قیود رقیب، کنترل شواهد و سازوکار امتیازدهی تشخیصی، امکان بررسی دقیق‌تر رفتار مدل را نسبت به معیارهای صرفاً مبتنی بر دقت فراهم می‌کند. نتایج تجربی نیز نشان دادند که حتی مدل‌هایی با دقت بالا می‌توانند در برخی موارد دچار خطای انتخاب مقدار از قید رقیب شوند و بررسی دقت زوجی می‌تواند ناپایداری‌هایی را آشکار کند که در ارزیابی سؤال‌محور به‌تنهایی قابل مشاهده نیستند.

با توجه به محدودیت‌های پژوهش، نتایج حاضر نباید به همه مدل‌های زبانی یا تمام کاربردهای مالی تعمیم داده شوند. با این حال، چارچوب ارائه‌شده می‌تواند به عنوان یک مبنای کنترل‌شده برای مطالعه دقیق‌تر قابلیت اعتماد مدل‌ها در پرسش‌وپاسخ مالی و توسعه روش‌های ارزیابی و کاهش خطاهای اتصال قید به مقدار مورد استفاده قرار گیرد.

منابع:

- [1] A. Jadhav and V. Mirza, "Large language models in equity markets: applications, techniques, and insights," *Frontiers in Artificial Intelligence*, vol. 8, 2025.
- [2] Z. Chen, W. Chen, C. Smiley, S. Shah, I. Borova, D. Langdon, R. Moussa, M. Beane, T.-H. Huang, B. Routledge, and W. Y. Wang, "FinQA: A Dataset of Numerical Reasoning over Financial Data," in *Proceedings of EMNLP*, pp. 3697–3711, 2021. DOI: 10.18653/v1/2021.emnlp-main.300.
- [3] F. Zhu, W. Lei, Y. Huang, C. Wang, S. Zhang, J. Lv, F. Feng, and T.-S. Chua, "TAT-QA: A Question Answering Benchmark on a Hybrid of Tabular and Textual Content in Finance," in *Proceedings of ACL-IJCNLP*, pp. 3277–3287, 2021. DOI: 10.18653/v1/2021.acl-long.254.
- [4] P. Islam, A. Kannappan, D. Kiela, R. Qian, N. Scherrer, and B. Vidgen, "FinanceBench: A New Benchmark for Financial Question Answering," *arXiv preprint arXiv:2311.11944*, 2023. DOI: 10.48550/arXiv.2311.11944.
- [5] Z. Ji, N. Lee, R. Frieske, T. Yu, D. Su, Y. Xu, E. Ishii, Y. J. Bang, A. Madotto, and P. Fung, "Survey of Hallucination in Natural Language Generation," *ACM Computing Surveys*, vol. 55, no. 12, Article 248, pp. 1–38, 2023. DOI: 10.1145/3571730.
- [6] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W.-T. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," in *Advances in Neural Information Processing Systems (NeurIPS)*, vol. 33, 2020.
- [7] K. Olorunnimbe and H. Viktor, "Deep learning in the stock market—A systematic survey of practice, backtesting, and applications," *Artificial Intelligence Review*, vol. 56, pp. 2057–2109, 2023. DOI: 10.1007/s10462-022-10226-0.
- [8] Z. Hu, Y. Zhao, and M. Khushi, "A survey of Forex and stock price prediction using deep learning," *Applied System Innovation*, vol. 4, no. 1, Article 9, 2021. DOI: 10.3390/asi4010009.
- [9] W. Ge, P. Lalbakhsh, L. Isai, A. Lenskiy, and H. Suominen, "Neural network-based financial volatility forecasting: A systematic review," *ACM Computing Surveys*, vol. 55, 2022. DOI: 10.1145/3483596.
- [10] O. Mane and S. Kandasamy, "Stock Market Prediction using Natural Language Processing – A Survey," in *Computer Science and Information Technology Trends (CSIT '22)*, pp. 33–48, 2022. DOI: 10.5121/csit.2022.121404.
- [11] S. R. Wicaksono, R. Setiawan, and Purnomo, "Candlestick pattern research analysis, future and beyond: A systematic literature review using PRISMA," *Journal of Computer Science and Technology Studies*, vol. 4, pp. 157–164, 2022. DOI: 10.32996/jcsts.2022.4.2.19.
- [12] G. Cohen, "Algorithmic trading and financial forecasting using advanced artificial intelligence methodologies," *Mathematics*, vol. 10, Article 3302, 2022. DOI: 10.3390/math10183302.
- [13] T.-T. Ho and Y. Huang, "Stock Price Movement Prediction Using Sentiment Analysis and CandleStick Chart Representation," *Sensors*, vol. 21, no. 23, Article 7957, 2021. DOI: 10.3390/s21237957.
- [14] M. J. Page et al., "The PRISMA 2020 statement: an updated guideline for reporting systematic reviews," *BMJ*, vol. 372, n71, 2021. DOI: 10.1136/bmj.n71.
- [15] J. Choe et al., "Hierarchical Retrieval with Evidence Curation for Open-Domain Financial Question Answering on Standardized Documents," *Findings of ACL 2025*, pp. 16663–16681, 2025. DOI: 10.18653/v1/2025.findings-acl.855.
- [16] Q. Dai, B. Heinzerling, and K. Inui, "Representational Analysis of Binding in Language Models," in *Proceedings of EMNLP*, pp. 17468–17493, 2024. DOI: 10.18653/v1/2024.emnlp-main.967.